동국대학교 WISE캠퍼스

설명 가능한 인공지능(XAI)을 활용한 네트워크 침입 탐지 시스템의 개발

Development of an Explainable AI-based Network Intrusion Detection System

지도교수 김진석
동국대학교 과학기술대학 컴퓨터공학과 김성연

01
서론
Introduction

연구 배경

사이버 공격이 다양해지면서 기존의 서명 기반 침입 탐지 시스템은 미탐과 변종 공격 대응에 한계를 보이고 있다.

이를 보완하기 위해 네트워크 트래픽의 통계적 패턴을 학습하는 머신러닝 기반 IDS 연구가 활발히 진행되었으나, 대부분의 고성능 모델은 내부 의사결정 과정을 파악하기 어려운 블랙박스 구조를 가져 보안 전문가가 결과를 신뢰하고 활용하는 데 제약이 존재한다.

실제 운영 환경에서는 탐지 여부뿐 아니라 "왜 이 트래픽이 공격으로 판단되었는지"에 대한 근거가 사고 분석, 대응 전략 수립, 정책 개선에 필수적이다.

이에 따라 높은 탐지 성능과 더불어 예측 근거를 직관적으로 제시할 수 있는 설명 가능한 인공지능(XAI)을 통합한 침입 탐지 시스템에 대한 필요성이 대두되고 있다.

연구 목적

본 연구의 목적은 IDS의 탐지 성능을 유지하면서도 모형에 대한 해석이 가능하도록 하는 설명 가능한 IDS(IDS-XAI) 시스템을 설계 및 구현하는 데 있다.

이를 위해 구조적 복잡도가 상이한 세 가지 모델을 대상으로, UNSW-NB15[5] 네트워크 트래픽 데이터셋을 이용해 침입 탐지 성능을 비교한다. 이후 블랙박스 모델에 LIME과 SHAP을 적용하여 각 입력 특성이 예측에 기여한 정도를 시각화하고, 화이트박스 모델인 의사결정트리의 규칙 기반 설명과 블랙박스 모델의 XAI 기반 설명을 비교하여 설계한 IDS-XAI 시스템의 해석 가능성을 검증한다.

최종적으로는 정확도 손실을 최소화하면서도 설명 가능한 근거를 제공하는 IDS-XAI 시스템 프로토타입을 구현하고, 보안 전문가의 대응 정책 수립을 지원할 수 있는 실무 적용 가능성을 검토한다. 제안하는 IDS-XAI 시스템은 고성능 블랙박스 모델을 완전히 대체하기보다는 모델의 판단 근거를 보조적으로 해석하는 설명 모듈로서 기능하도록 설계하였다.

02
이론적 배경
Experimental

01 침입 탐지 시스템(IDS)

침입 탐지 시스템(IDS)은 네트워크 트래픽이나 시스템 로그를 모니터링하여 비정상 행위를 탐지하는 보안 기술로, 전통적으로 서명 기반 및 이상 징후 기반 접근이 사용되어 왔다는 점에서 출발한다.

최근에는 네트워크 트래픽의 통계적 특성과 패턴을 학습하여 공격 여부를 자동 분류하는 머신러닝 기반 IDS 연구가 활발히 이루어지고 있으며, 분류 문제로 침입 탐지를 정식화하여 다양한 알고리즘의 성능을 비교·분석하고 있다.

특히 다층 퍼셉트론(MLP), XGBoost와 같은 모델은 대규모 네트워크 데이터셋을 대상으로 높은 탐지 성능을 보이는 대표적인 기법으로 활용된다.

02 XAI와 모델의 해석 가능성

머신러닝 기반 IDS가 고도화되면서 모델의 예측 결과를 사람이 이해할 수 있는 형태로 설명하는 설명 가능한 인공지능(XAI)의 필요성이 부각되고 있다.

블랙박스 모델은 높은 탐지 성능을 제공하지만 내부 의사결정 과정을 직접 해석하기 어렵기 때문에 보안 전문가가 결과를 신뢰하고 정책에 반영하는 데 제약이 존재한다.

XAI는 특징 중요도, 국소적·전역적 설명, 의사결정 경로 시각화와 같은 기법을 통해 모델이 어떤 입력 특징을 근거로 공격 여부를 판단했는지 명시적으로 제시하고자 한다. 이를 통해 침입 탐지 결과에 대한 신뢰성을 확보하고, 오탐·미탐 사례 분석과 규칙 개선에 필요한 근거 정보를 제공할 수 있다.

03 LIME과 SHAP 기반 모델 설명 기법

LIME(Local Interpretable Model-agnostic Explanations)은 개별 샘플 주변의 국소적인 입력 공간을 생성하고, 단순한 선형 모델을 학습하여 특정 예측에 기여한 특징을 추정하는 기법이다. 모델 비종속적 특성을 가지므로 다양한 분류기에 적용 가능하며, 각 인스턴스 단위의 직관적인 설명을 제공한다.

SHAP(SHapley Additive exPlanations)은 게임이론의 Shapley value에 기반하여 각 특징의 기여도를 공정하게 분배하는 방법으로, 일관된 특징 중요도와 전역·국소 설명을 동시에 지원한다. 두 기법은 블랙박스 모델의 예측 근거를 시각적으로 표현할 수 있어, 침입 탐지 모델의 해석 가능성을 높이고 화이트박스 모델의 규칙 기반 결과와 비교·분석하는 데 유용한 XAI 도구로 활용된다.

03
시스템 설계
architecture

시스템 아키텍처 | IDS-XAI 시스템의 구성도

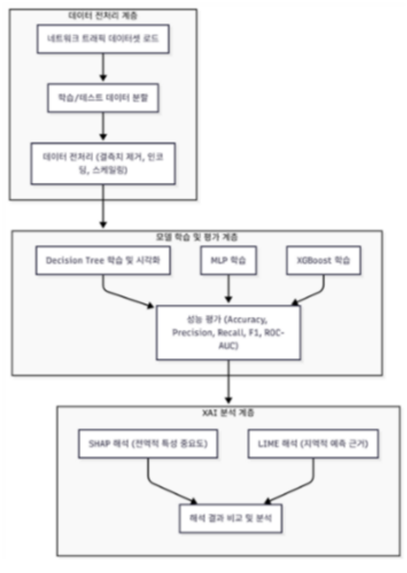

데이터셋: UNSW-NB15
실험 모델: 의사결정트리, MLP, XGBoost

01 데이터 전처리
데이터 전처리 단계에서는 불필요 속성을 제거하고, 학습·테스트 데이터를 분리한 뒤 결측치 처리, One-Hot 인코딩, StandardScaler 기반 정규화를 수행하였다.

02 모델 학습 및 평가
모델 학습·평가 단계에서는 의사결정트리, MLP, XGBoost를 학습시키고 정확도, 정밀도, 재현율 등 분류 성능 지표로 모델의 성능을 비교하였다.

03 XAI 분석
XAI 분석 단계에서는 블랙박스 모델인 MLP와 XGBoost에 LIME과 SHAP을 적용하여 인스턴스별 특징 기여도와 전역 중요도를 시각화하고, 의사결정트리와 비교하였다.

04
프로그램 구현
Implementation

시스템 개발 환경 | 하드웨어 및 플랫폼

구분	사양
개발 플랫폼	Google Colaboratory (Standard)
런타임 유형	Python 3 (CPU 런타임)
CPU	Google Colab 가상 머신
RAM	약 12.7 GB

시스템 개발 환경 | 소프트웨어 및 라이브러리

구분	내용
운영체제 (OS)	Linux (Colab 가상 머신 기본 환경)
개발 언어	Python 3.10
데이터 처리	Pandas, NumPy
머신러닝	Scikit-learn, XGBoost
XAI	LIME, SHAP
시각화	Matplotlib, Seaborn

IDS-XAI 시스템 실행 구성도

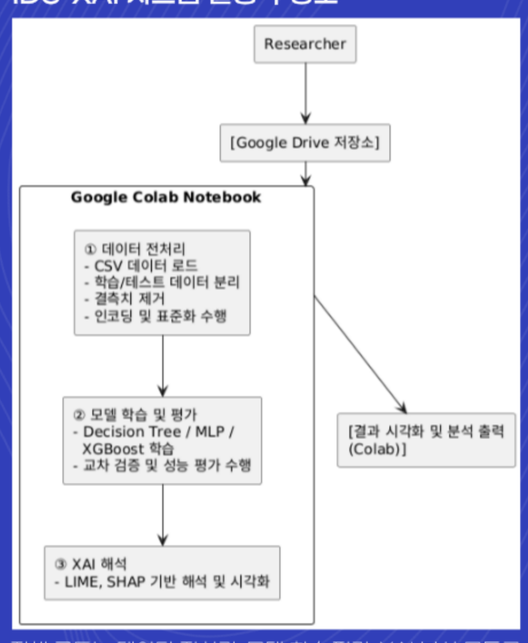

전체 코드는 데이터 전처리, 모델 학습·평가, XAI 분석 모듈로 구성되며, 하나의 Colab 노트북에서 데이터 로드부터 모델 해석까지 일관된 파이프라인을 실행하도록 구현하였다.

05
실험
Experiment

성능 지표 | 의사결정트리, MLP, XGBoost

모델	정확도	정밀도	재현율	F1-Score	ROC-AUC
의사결정트리	0.86	0.85	0.84	0.84	0.87
MLP	0.90	0.91	0.89	0.90	0.92
XGBoost	0.97	0.96	0.95	0.95	0.97

성능 비교는 우열 판단이 아닌, 모델의 성능과 해석 가능성 간 상충 관계를 검증하기 위한 것이다.

의사결정트리 | 의사결정트리의 특성 중요도 및 규칙 분기 구조도

첫 번째 그림은 주요 탐지 기준 특성의 상대적 중요도를 나타내며, sttl 등의 특성이 주요 결정 요인으로 작용함을 보여준다.

두 번째 그림은 모델의 규칙 분기 구조를 표현한 결과로 각 노드의 분기 기준을 따라 공격 여부가 판정되는 과정을 파악할 수 있다. 이를 통해 해석 가능한 모델의 의사결정 구조를 확인하고, 이후 블랙박스 모델의 XAI 해석 결과와 비교할 기준을 마련한다.

MLP-LIME 해석 결과 | MLP 모델의 개별 예측 설명

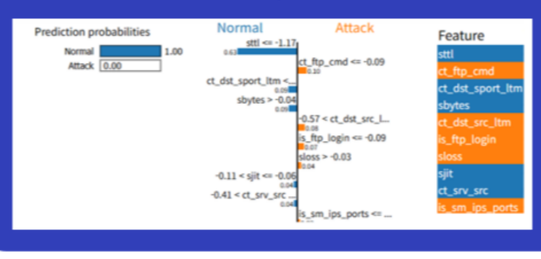

그림은 LIME을 이용해 MLP 모델의 개별 예측 분류 결과를 설명한 것이다.

LIME 분석 결과, 모델은 sttl < -1.17 조건을 핵심 근거로 삼아 해당 예측을 1.00의 확률로 '정상'이라 확신했다. 이는 긍정·부정 요인을 대조해 직관적인 해석을 제공하며, 도출된 주요 특성은 의사결정트리의 주요 변수와 일관된 경향을 보인다. 이러한 결과는 LIME이 블랙박스 모델의 판단 과정을 타당하고 신뢰성 있게 설명하고 있음을 시사한다.

05
실험
Experiment

XGBoost | 전역적 특성 중요도 분석 결과

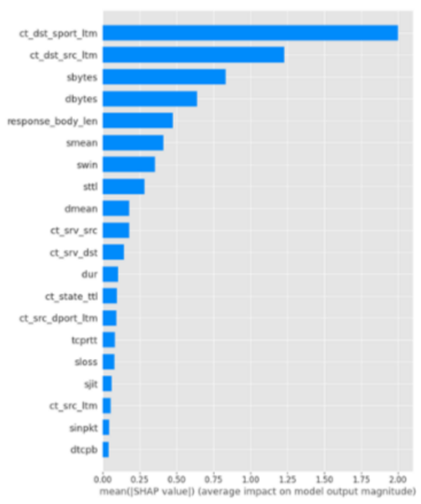

전역 특성 중요도 분석 결과 ct_dst_sport_ltm, sbytes, ct_dst_src_ltm가 예측에 가장 큰 영향을 미치는 변수로 나타났으며 의사결정트리와도 일부 주요 특성을 공유하는 것으로 확인되었다.

XGBoost | sttl 특성 SHAP 의존도 및 의사결정 경로 시각화

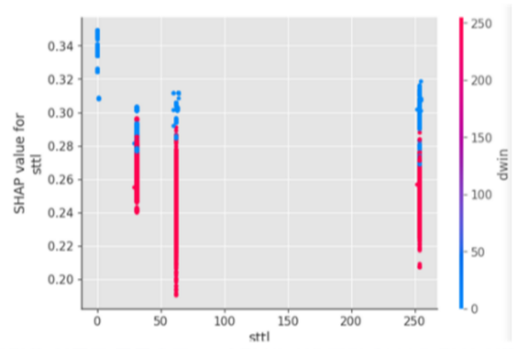

이 그림은 의존도 플롯으로, sttl 값 변화에 따라 SHAP 값이 어떻게 달라지는지와 dwin 색상을 통해 두 특성의 상호작용이 공격 판정에 미치는 영향을 나타낸다.

이 그림은 force plot으로, 특정 트래픽 샘플 하나에 대해 sttl, dwin 등이 예측 값을 정상·공격 방향으로 얼마나 이동시키는지를 시각화한다.

이 그림은 decision plot으로, 여러 샘플에 대해 주요 특성의 SHAP 값이 누적되며 최종 예측에 도달하는 경로를 표현하여 sttl을 포함한 상위 특성들이 전역적으로 모델 판단에 기여하는 패턴을 한눈에 보여준다.

06
결론
Conclusions

연구 요약

본 연구는 블랙박스 기반 침입 탐지 모델의 낮은 해석 가능성 문제를 완화하기 위해 설명 가능한 인공지능(XAI)을 통합한 IDS-XAI 시스템을 설계한 것이다.

제안 시스템은 데이터 전처리, 모델 학습·평가, XAI 해석의 세 계층으로 구성되며, 의사결정트리, MLP, XGBoost 세 모델을 동일 파이프라인에서 비교·분석할 수 있도록 하였다.

실험 결과 XGBoost가 가장 높은 침입 탐지 성능을 보였고, MLP는 중간, 의사결정트리는 상대적으로 낮은 성능을 기록하였으나 규칙 기반 구조를 통해 높은 해석 용이성을 제공하였다.

이에 의사결정트리를 해석의 기준선으로 두고, MLP와 XGBoost에 LIME과 SHAP을 적용하여 개별 예측과 전역 특성 중요도를 분석한 결과, 패킷 크기와 세션·트래픽 특성 등 일부 핵심 특성에서 세 모델이 공통적으로 주목하는 양상을 확인하였다. 이와 같은 결과는 XAI 기법을 활용하여 블랙박스 모델의 판단 근거를 내부 일관성과 도메인 지식 측면에서 점검할 수 있는 가능성을 보여준다.

연구 의의 및 향후 과제

본 연구에서 구현한 IDS-XAI 시스템은 세 가지 모델을 통합적으로 평가하고, XAI 기법을 통해 블랙박스 모델의 예측 근거를 부분적으로 드러냄으로써 성능과 해석 가능성을 함께 고려한 침입 탐지 모델 평가 틀을 제시하였다는 점에서 의의를 가진다. 이는 실무 환경에서 보안 전문가의 의사결정을 지원할 수 있는 하나의 방안을 제공한다.

다만 본 연구는 UNSW-NB15 단일 데이터셋을 활용한 오프라인 실험에 한정되어 있으며, 실시간 트래픽 처리, 다양한 네트워크 환경, 최신 공격 유형에 대한 일반화 가능성을 직접적으로 검증하지 못하였다.

향후 연구에서는 실시간 데이터 스트리밍을 처리할 수 있는 온라인 학습 기반 IDS-XAI 구조로 확장하고, 실제 운영 환경의 트래픽과 다양한 공개 데이터셋을 활용한 교차 검증을 통해 제안 시스템의 안정성과 실효성을 평가하고자 한다.