졸업자격실험보고서

설명 가능한 인공지능(XAI)을 활용한 네트워크 침입 탐지 시스템의 개발

지도교수 김진석

컴퓨터공학과
동국대학교 WISE캠퍼스

김성연

2025

졸업자격실험보고서

설명 가능한 인공지능(XAI)을 활용한 네트워크 침입 탐지 시스템의 개발

Development of an Explainable AI-based Network Intrusion Detection System

김성연

지도교수 김진석

본 보고서를 졸업자격 실험보고서로 제출함.
2025년 11월 18일

김성연의 졸업자격 실험보고 통과를 인준함.
2025년 11월 18일

주 심 오 승 현 (인)

부 심 김 진 석 (인)

동국대학교 컴퓨터공학과

목 차

1. 서론 ····· 1
1.1 연구배경 및 목적 ····· 1
1.2 연구범위 ····· 1
2. 이론적 배경 ····· 3
2.1 네트워크 침입 탐지 연구 ····· 3
2.2 네트워크 침입 탐지 연구에서 XAI의 필요성 ····· 4
2.3 XAI 기반 네트워크 침입 탐지 연구 ····· 4
3. 시스템 설계 ····· 5
3.1 요구사항 ····· 5
3.2 아키텍처 설계 ····· 11
3.3 상세설계 ····· 13
4. 프로그램 구현 ····· 16
4.1 시스템 환경 ····· 16
4.2 시스템 구성 ····· 16
4.3 시스템 구현 ····· 18
5. 실험 ····· 20
5.1 기능 검증 ····· 20
5.2 모델 성능 평가 ····· 20
5.3 XAI 해석 결과 ····· 22
6. 결론 ····· 27

그 림 목 차

[그림 3-1] IDS-XAI 시스템의 유스케이스 다이어그램 ····· 6
[그림 3-2] IDS-XAI 시스템의 계층적 구성도 ····· 11
[그림 3-3] IDS-XAI 시스템 클래스 다이어그램 ····· 12
[그림 3-4] IDS-XAI 시스템 순차 다이어그램 ····· 13
[그림 3-5] IDS-XAI 시스템 데이터 전처리 절차 순서도 ····· 14
[그림 4-1] IDS-XAI 시스템 실행 구성도 ····· 17
[그림 4-3] 모델 학습 및 평가 알고리즘 ····· 19
[그림 4-4] XAI 분석 알고리즘 ····· 19
[그림 5-1] 의사결정트리 특성 중요도 ····· 21
[그림 5-2] 의사결정트리 규칙 분기 구조도 ····· 21
[그림 5-3] MLP 모델의 개별 예측 설명(LIME) ····· 22
[그림 5-4] XGBoost 모델의 전역적 특성 중요도 (SHAP) ····· 24
[그림 5-5] 'sttl' 특성과 'dwin' 특성 간의 상호작용 (SHAP) ····· 25
[그림 5-6] XGBoost 모델의 단일 예측에 대한 특성 기여도 (SHAP) ····· 25
[그림 5-7] XGBoost 모델의 다수 샘플의 누적 의사결정 경로 (SHAP) ····· 26

표 목 차

[표 3-1] 기능적 요구사항 ····· 5
[표 3-2] UC1: 데이터 로드 ····· 7
[표 3-3] UC2: 학습/테스트 데이터 분할 ····· 7
[표 3-5] UC4: 화이트박스 모델 학습 (Decision Tree) ····· 8
[표 3-6] UC5: 블랙박스 모델 학습 (MLP / XGBoost) ····· 8
[표 3-7] UC6: 모델 평가 ····· 9
[표 3-8] UC7: SHAP 해석 ····· 9
[표 3-9] UC8: LIME 해석 ····· 10
[표 3-10] UC9: 모델 해석 결과 비교 ····· 10
[표 3-11] UNSW-NB15 데이터셋 주요 특성 ····· 14
[표 4-1] 시스템 개발 환경 (하드웨어 및 플랫폼) ····· 16
[표 4-2] 시스템 개발 환경 (소프트웨어 및 라이브러리) ····· 16
[표 5-1] IDS-XAI 시스템 기능 검증 결과 요약 ····· 20
[표 5-2] 모델별 성능 비교표 ····· 20

1. 서론

1.1 연구배경 및 목적

최근 사이버 공격이 고도화되면서, 패턴 일치 방식에 의존해 알려진 공격을 탐지하는 기존 서명 기반(Signature-based) 침입 탐지 시스템(IDS)은 미확인 공격(Zero-day)이나 변종 공격에 효과적으로 대응하기 어렵다[1]. 이러한 한계를 보완하기 위해 머신러닝(ML) 기반 IDS 연구가 활발히 수행되었으며, 이러한 모델은 높은 탐지 정확도를 바탕으로 잠재적 침입 행위를 자동 식별하는 데 기여해 왔다[2]. 그러나 다수의 머신러닝, 특히 딥러닝(DL) 기반 모델은 내부 구조가 복잡하고 비선형적이어서 특정 행위를 침입으로 판단한 근거를 명확히 제시하기 어렵다[3]. 이로 인해 보안 전문가가 침입에 대한 적절한 대응 전략을 수립하는 과정에서 어려움이 발생한다[4].

설명 가능한 인공지능(XAI, Explainable AI)은 모델의 예측 결과에 대해 사람이 이해할 수 있는 형태의 근거를 제공함으로써 이러한 한계를 완화할 수 있는 대안으로 주목받고 있다. 특히 네트워크 침입 탐지 분야에서는 모델이 어떤 입력 특성을 근거로 침입 여부를 판단했는지 명시적으로 제시함으로써, 보안 분석가가 탐지 결과를 신뢰하고 대응 정책을 개선할 수 있는 기반을 마련하는 것이 중요하다.

이에 본 연구에서는 IDS의 탐지 성능을 유지하면서도 모형에 대한 해석이 가능하도록 하는 설명 가능한 IDS(IDS-XAI) 시스템을 설계하는 것을 목표로 한다. 이를 위해 구조적 복잡도가 상이한 세 가지 모델을 대상으로, UNSW-NB15[5] 네트워크 트래픽 데이터셋을 이용해 침입 탐지 성능을 비교한다. 이후 블랙박스 모델에 LIME과 SHAP을 적용하여 각 입력 특성이 예측에 기여한 정도를 시각화하고, 화이트박스 모델인 의사결정트리의 규칙 기반 설명과 블랙박스 모델의 XAI 기반 설명을 비교하여 설계한 IDS-XAI 시스템의 해석 가능성을 검증한다.

최종적으로는 정확도 손실을 최소화하면서도 설명 가능한 근거를 제공하는 IDS-XAI 시스템 프로토타입을 구현하고, 보안 전문가의 대응 정책 수립을 지원할 수 있는 실무 적용 가능성을 검토한다. 제안하는 IDS-XAI 시스템은 고성능 블랙박스 모델을 완전히 대체하기보다는 모델의 판단 근거를 보조적으로 해석하는 설명 모듈로서 기능하도록 설계하였다. 본 연구의 가치는 단일 성능 지표의 향상을 넘어, 모델의 신뢰성과 투명성을 강화하여 보안 인공지능이 나아갈 방향을 제시하는 데 있다.

1.2 연구범위

본 연구는 UNSW-NB15 네트워크 트래픽 데이터셋을 대상으로, 머신러닝 기반 침입 탐지 모델의 해석 가능성과 신뢰성을 동시에 향상하는 것을 목표로 한다. 이를 위해 구조적 특성이 서로 다른 의사결정트리, MLP, XGBoost를 실험 대상으로 선정하고, 각 모델의 탐지 성능과 설명 가능성을 함께 평가하였다.

연구 절차는 다음과 같다. 먼저 원본 데이터를 학습용과 테스트용으로 분할한 뒤 결측치와 불필요한 특성을 제거하고, 범주형 변수는 원-핫 인코딩(one-hot encoding), 수치형 변수는 표준화(standardization)를 통해 전처리하였다. 그다음 전처리된 데이터를 이용해 세 모델을 학습하고, 정확도, 정밀도, 재현율, F1-score, ROC-AUC 지표로 성능을 평가하였다. 해석 단계에서 의사결정트리는 화이트박스 기준 모델로 설정하였고, XGBoost와 MLP에 한하여 LIME과 SHAP을 적용하여 예측의 근거를 시각화하고 특성 기여도를 분석하였다. 해석 가능성 비교

는 기준 모델인 의사결정트리에서 제시한 규칙과 특성 중요도, 그리고 XGBoost와 MLP에 대한 LIME과 SHAP의 전역 중요도를 대조하는 방식으로 수행하였으며, 상위 특성의 중복 정도와 중요도 순위의 일치 정도를 중심으로 결과를 정리하였다.

한편, 본 연구는 다음과 같은 한계 및 제외 범위를 가진다. 첫째, 본 연구는 정적 데이터 분석에 초점을 두었으며, 실시간 네트워크 트래픽을 기반으로 한 온라인 침입 탐지 시스템 구현은 포함하지 않았다. 둘째, 자원 제약 및 환경의 한계로 인해 딥러닝 기반 대규모 신경망 모델은 실험 대상에 포함하지 않았다. 이러한 범위 설정을 통해 성능 저하를 최소화하면서 설명 가능한 근거를 제시하는 IDS-XAI의 설계와 평가 절차를 제시하고, 보안 실무에서의 신뢰 가능한 적용 가능성을 뒷받침하고자 한다.

2. 이론적 배경

2.1 네트워크 침입 탐지 연구

네트워크 침입 탐지 시스템(IDS: Intrusion Detection System)은 네트워크나 호스트의 트래픽을 감시하고 정상 행위와 침입 행위를 구분하여 보안을 유지하기 위해 설계되었다. IDS의 개념은 Denning[6]이 1987년 발표한 논문 An Intrusion-Detection Model에서 제안한 이상 행위 탐지 모델을 계기로 본격적으로 연구되기 시작하였다.

초기의 IDS는 서명 기반(Signature-based) 탐지 방식을 중심으로 발전하였다. 서명 기반 방식은 이미 알려진 공격 패턴이나 문자열 서명을 데이터베이스에 저장하고, 네트워크 트래픽이나 로그에서 동일한 패턴이 발견되면 침입으로 판단하는 방식이다[7]. 이 방식은 구현이 간단하고 알려진 공격에 대한 정확도가 높지만, 새로운 공격이나 변형된 공격에는 대응하기 어렵고 서명 데이터베이스를 지속적으로 갱신해야 한다는 한계가 있다.

이러한 한계를 보완하기 위해 1990년대 후반부터 데이터마이닝과 머신러닝을 활용한 침입 탐지 연구가 활발히 진행되었다. Lee와 Stolfo[8]는 머신러닝 기법을 IDS에 적용하여, 데이터로부터 정상 및 비정상 행위의 패턴을 학습함으로써 알려지지 않은 공격을 탐지할 수 있음을 제시하였다. 기존의 서명 기반 탐지 방식이 이미 알려진 공격만을 식별할 수 있었다면, 머신러닝 기반 접근법은 데이터의 통계적 특성과 행동 패턴을 학습하여 새로운 유형의 공격이나 변형된 침입 시도까지 탐지할 수 있다는 점에서 중요한 전환점을 마련하였다. 이로 인해 다양한 머신러닝 모델이 IDS 연구에 적용되기 시작하였다.

이 가운데 의사결정트리(Decision Tree)[9]는 각 분기 규칙이 명확하게 표현되어 판단 근거를 직접 추적할 수 있는 해석 가능한 모델로 평가된다. 그러나 구조가 단순하고 데이터의 복잡한 비선형 관계를 충분히 학습하지 못하기 때문에 고도화된 네트워크 공격이나 다양한 형태의 침입 패턴을 탐지하는 데에는 한계가 존재한다. 이러한 성능적 제약을 극복하기 위해 다층 구조를 갖춘 다층 퍼셉트론(MLP, Multi-Layer Perceptron)[10]과 부스팅 기법을 적용한 XGBoost(eXtreme Gradient Boosting)[11]와 같은 복합 구조의 모델들이 제안되었다.

MLP와 XGBoost는 복잡한 데이터 구조를 학습하여 높은 탐지 정확도를 달성할 수 있었으나, 내부 연산 과정이 다층 신경망 또는 트리 결합 구조로 이루어져 있어 사람이 판단 근거를 명확히 이해하기 어렵다. 모델의 복잡도가 높아짐에 따라 탐지 성능은 개선되었지만, 동시에 내부 판단 근거를 해석하기 어려운 한계가 발생하였다. 이러한 현상은 이른바 '블랙박스(black-box)' 문제로 불린다.

블랙박스라는 용어는 Ashby[12]가 1956년 An Introduction to Cybernetics에서 제시한 개념으로, 내부 구조는 보이지 않고 입력과 출력만 관찰 가능한 시스템을 의미한다. 인공지능 분야에서는 모델이 예측을 내린 근거를 사람이 명확히 이해할 수 없는 상태를 지칭한다. 이에 대응되는 개념은 '화이트박스(white-box)'로, 의사결정트리와 같이 입력과 출력 간의 관계가 명시적이며 사람이 모델의 판단 근거를 추적할 수 있는 모델을 의미한다[13].

결과적으로 IDS 연구는 성능과 해석 가능성 사이의 상충 관계 속에서 발전해 왔다. 해석이 용이한 화이트박스 모델은 복잡한 공격 패턴을 충분히 학습하지 못하고, 반대로 블랙박스 모델은 높은 정확도를 보이지만 판단 근거를 설명하기 어렵다. 이러한 한계를 해결하기 위한 접근법으로 설명 가능한 인공지능(XAI: Explainable Artificial Intelligence)이 주목받고 있다.

2.2 네트워크 침입 탐지 연구에서 XAI의 필요성

앞서 언급한 바와 같이, 머신러닝 기반 침입 탐지 모델의 블랙박스 특성은 탐지 결과에 대한 신뢰성을 저하시키는 주요 원인으로 작용한다. 이러한 문제를 해결하기 위해 등장한 개념이 바로 설명 가능한 인공지능(XAI)이다[14]. XAI는 인공지능 모델의 판단 근거를 사람이 이해할 수 있는 형태로 제시함으로써, 모델의 투명성, 신뢰성, 그리고 해석 가능성을 확보하는 것을 목표로 한다.

XAI의 대표적인 접근법으로는 Ribeiro 등[15]이 제안한 LIME(Local Interpretable Model-Agnostic Explanations)과, Lundberg와 Lee[16]가 제시한 SHAP(SHapley Additive exPlanations)이 있다. LIME은 개별 예측 샘플 단위로 모델의 판단 근거를 분석하는 기법으로, 테스트 데이터 중 일부 샘플을 선택하여 해당 입력에 대해 모델이 어떤 특성에 가중치를 두었는지를 시각화한다. 이 과정을 통해 MLP나 XGBoost와 같이 구조가 복잡한 모델이라도 특정 공격 트래픽을 탐지한 이유를 직관적으로 파악할 수 있다. 반면 SHAP은 게임 이론의 샤플리 값(Shapley value)에 기반하여 모델의 예측을 설명하는 접근법을 제공한다. SHAP은 개별 예측 단위로 각 특성이 예측에 기여한 값을 계산하며, 이러한 값들을 집계하여 모델 전체의 전역적 특성 중요도, 상호작용, 의존성 등을 분석할 수 있게 한다. 이 기법을 통해 모델이 어떤 변수를 가장 중요한 탐지 기준으로 삼았는지, 그리고 변수 간의 관계가 예측에 어떤 영향을 주는지를 검증할 수 있다.

이러한 설명 기법들은 탐지 결과와 함께 확인 가능한 근거를 제공하여 결과 검증을 지원하고 해석 가능성 확보에 기여한다. 따라서 XAI는 단순한 성능 보조 기술이 아니라, 신뢰할 수 있는 침입 탐지의 적용을 위해 필요한 핵심 요소로 평가된다[17].

2.3 XAI 기반 네트워크 침입 탐지 연구

최근 침입 탐지 시스템(IDS) 분야에서는 모델의 예측 근거를 시각적으로 설명하고 탐지 결과의 신뢰성을 향상시키기 위해 설명 가능한 인공지능(XAI)을 적용하는 연구가 활발히 진행되고 있다. 정일옥 등[18]은 IDS에 XAI 기법을 적용하여 모델 판단 근거의 시각화를 통해 신뢰성을 강화하는 방법을 제안하였다. Arreche 등[19]은 LIME과 SHAP을 결합한 하이브리드 접근법을 통해 IDS의 판단 근거를 로컬 및 글로벌 수준에서 분석하는 프레임워크를 제시하였으며, Keshk 등[20]은 딥러닝 모델에 SHAP을 적용하여 IoT 환경에서의 침입 탐지 해석 가능성을 탐구하였다.

그러나 이러한 기존 연구들은 대부분 단일 모델 적용에 국한되거나, 모델의 구조적 복잡성에 따른 해석 가능성의 차이를 비교한 사례가 부족하다. 즉, 높은 탐지 성능에도 불구하고 모델의 판단 근거를 명확히 설명하지 못해 신뢰성을 확보하지 못하는 한계가 존재한다. 따라서 본 연구는 이러한 한계를 보완하는 것을 목적으로 한다. 구조적 복잡도가 상이한 세 가지 IDS 모델에 LIME과 SHAP을 병행 적용하고, 탐지 성능과 해석 가능성의 상관관계를 종합적으로 분석한다. 이를 통해 기존의 탐지 성능 중심 연구에서 나아가, 모델의 해석 가능성과 신뢰성을 동시에 확보하는 IDS 설계 방향을 제시하고자 한다.

3. 시스템 설계

본 장에서는 1장의 연구 목적과 2장의 선행연구 분석을 바탕으로, XAI를 적용한 IDS-XAI 시스템의 전체 설계 구조를 제시한다.

3.1 요구사항

본 연구의 IDS-XAI 시스템은 설명 가능한 인공지능 기법을 활용하여 침입 탐지 모델의 신뢰성과 해석 가능성을 향상시키는 것을 목표로 한다. 시스템은 데이터 처리에서부터 모델 학습, 평가, 그리고 XAI 기반 해석 및 비교에 이르는 일련의 절차를 수행하도록 구성되었다. 이를 위해 본 연구는 상이한 해석 가능성과 복잡도를 지닌 세 가지 머신러닝 모델인 의사결정트리, MLP, XGBoost를 채택하였다.

의사결정트리는 각 분기 규칙을 명확히 시각화할 수 있는 화이트박스 모델로, 통계적 해석이나 외부 XAI 도구의 도움 없이도 모델 자체가 자체적으로 해석 가능한 구조를 제공한다. 이를 통해 블랙박스 모델의 해석 결과(LIME, SHAP)와 비교할 수 있는 참조 기준을 마련하고, XAI 기법이 실제로 어느 수준까지 블랙박스 모델의 판단 과정을 재현할 수 있는지를 검증한다.

MLP는 은닉층을 통해 비선형 패턴을 학습하는 블랙박스 모델로, 본 연구에서는 LIME 기법을 적용하여 개별 예측 단위를 지역적으로 해석하였다.

XGBoost는 여러 결정트리를 결합한 그래디언트 부스팅 기반의 복합적인 구조의 블랙박스 모델로, 높은 성능을 보이지만 내부 구조가 다층적 트리 조합으로 구성되어 있어 단일 트리에 비해 해석이 훨씬 어렵다. 본 연구에서는 SHAP 기법을 활용하여 XGBoost의 전역적 특성 중요도와 특성 간 상호작용을 정량적으로 분석하였다.

세 모델의 구성은 단순한 알고리즘 비교가 아니라, 화이트박스인 의사결정트리의 해석을 기준선으로 삼아 블랙박스 모델(MLP, XGBoost)에 적용한 LIME과 SHAP의 설명 결과를 비교 및 검증하기 위한 설계이다. 이를 통해 정확도 손실을 최소화한 상태에서 설명 가능한 침입 탐지 시스템 구조를 제안한다. [표 3-1]은 이러한 설계를 근거로 기능적 요구사항을 요약한 것이다.

[표 3-1] 기능적 요구사항

구분	ID	요구사항
데이터 로드 및 분할	FR-1	네트워크 트래픽 데이터셋 CSV 파일 로드
	FR-2	학습 데이터 및 테스트 데이터를 분할해 사용
데이터 전처리	FR-3	결측치 제거, 범주형 인코딩, 수치형 스케일링 수행
모델 훈련 및 평가	FR-4	의사결정트리 학습 및 규칙 시각화
	FR-5	MLP 및 XGBoost 모델 학습
	FR-6	학습된 모델의 성능 지표 산출
XAI 기반 해석 및 비교	FR-7	SHAP을 통한 블랙박스 모델 해석
	FR-8	LIME을 활용한 블랙박스 모델의 개별 예측 단위 해석
	FR-9	의사결정트리 모델과 XAI의 해석 결과 비교 분석

3.1.1 유스케이스 다이어그램

[그림 3-1]은 본 연구에서 구현한 IDS-XAI 연구 시스템의 유스케이스 다이어그램을 나타낸 것이다. 전체 흐름은 데이터 로드로 시작하여, 학습용과 테스트용 분할 및 전처리 과정을 거친다. 전처리된 데이터는 화이트박스 모델인 의사결정트리와 블랙박스 모델인 MLP와 XGBoost의 학습에 사용되며, 이후 모델 평가로 이어진다. 마지막 단계에서 MLP와 XGBoost에 대해 LIME과 SHAP을 적용하여 설명을 생성하고, 그 결과를 의사결정트리의 규칙과 중요도와 비교하여 검증한다. 각 유스케이스의 구체적인 내용은 3.1.2절의 유스케이스 명세서에서 자세히 설명한다.

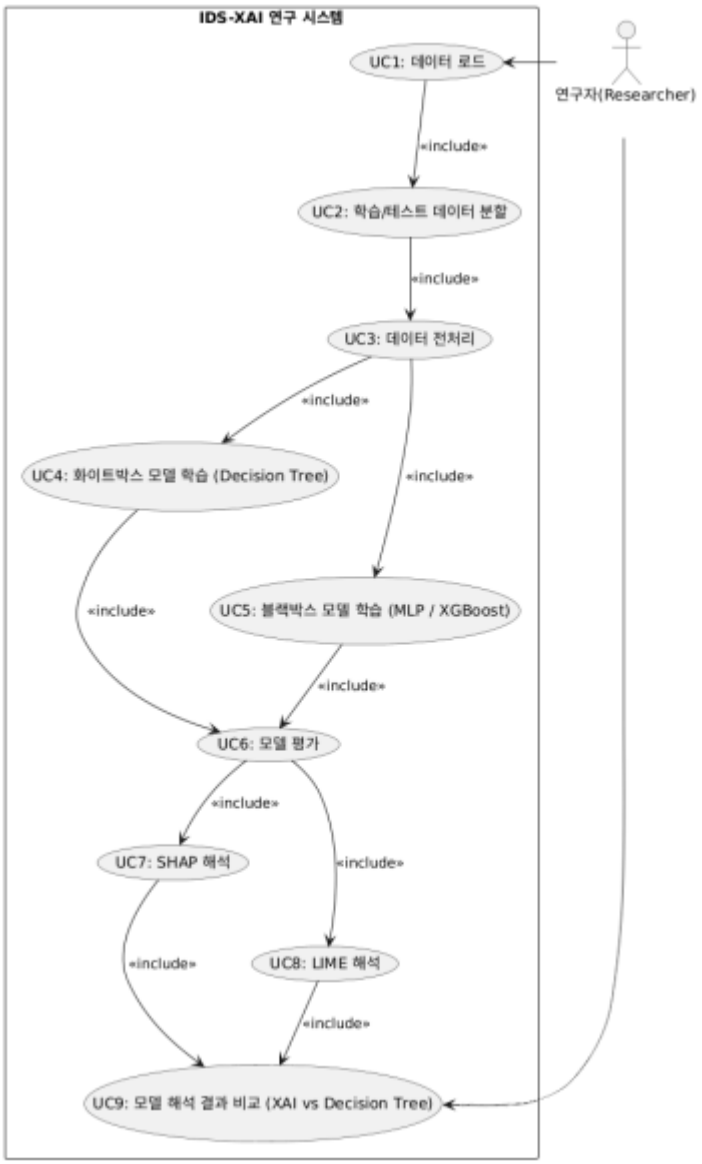

[그림 3-1] IDS-XAI 시스템의 유스케이스 다이어그램

3.1.2 유스케이스 명세서

이 절에서는 요구사항 명세서를 기반으로 각 유스케이스에 대한 상세 명세를 기술한다.

[표 3-2]는 데이터 로드 유스케이스의 명세로서, 연구자가 네트워크 트래픽 데이터셋을 시스템에 불러와 이후 전처리 단계에서 활용할 수 있도록 하는 과정을 정의한다. 기본 흐름은 데이터 파일을 읽고 요약 정보를 출력하는 절차로 구성되며, 파일이 존재하지 않거나 형식이 올바르지 않은 경우 실행을 중단하고 오류를 알리는 예외 흐름을 포함한다.

[표 3-2] UC1: 데이터 로드

이름	데이터 로드		관련 액터	연구자
설명	연구자가 분석에 사용할 데이터 파일을 시스템에 불러온다.			
사건 흐름	기본 흐름	1. 연구자가 데이터 로드를 요청한다. 2. 시스템은 지정된 경로에서 데이터 파일을 읽어온다. 3. 시스템은 데이터의 요약 정보(샘플, 컬럼 정보)를 화면에 출력한다.		
	대안 흐름	없음		
	예외 흐름	2a. 파일을 찾지 못할 경우, 스크립트 실행이 중단됨.		
조건	사전 조건	네트워크 트래픽 데이터셋이 지정된 경로에 존재해야 함.		
	사후 조건	데이터가 메모리에 로드되어 전처리 단계(UC2)에서 사용 가능함.		

[표 3-3]은 학습/테스트 데이터 분할 유스케이스의 명세를 제시한다. 연구자는 UC1에서 로드된 원본 데이터셋을 대상으로 학습용 및 테스트용 데이터 세트 생성을 요청하며, 시스템은 train_test_split() 함수를 이용하여 데이터를 분할한다. 생성된 각 데이터 세트는 이후 모델 학습 및 평가 단계(UC4~UC6)에서 활용할 수 있도록 저장·관리된다.

[표 3-3] UC2: 학습/테스트 데이터 분할

이름	학습/테스트 데이터 분할		관련 액터	연구자
설명	데이터를 학습용과 테스트용으로 구분한다.			
사건 흐름	기본 흐름	1. 연구자가 데이터 분할 기능을 실행한다. 2. 시스템이 train_test_split() 함수를 이용해 데이터를 분할한다. 3. 학습 데이터와 테스트 데이터를 별도로 저장한다.		
	대안 흐름	없음		
	예외 흐름	없음		
조건	사전 조건	데이터 로드(UC1)가 반드시 선행(포함)되어야 함.		
	사후 조건	데이터가 학습 세트와 테스트 세트로 분할되어 다음 단계(UC3)에서 사용 가능함.		

[표 3-4]는 데이터 전처리 유스케이스를 나타낸 것으로, 연구자가 분할된 데이터를 머신러닝 모델이 처리 가능한 형태로 변환하는 절차를 기술한다. 시스템은 학습 데이터를 기준으로 결측치 제거, 인코딩, 스케일링 규칙을 학습한 후 이를 학습·테스트 데이터에 동일하게 적용하며, 문자열 형태의 정답 데이터를 숫자형으로 변환하여 모델 학습에 사용할 수 있도록 전처리를 완료한다.

[표 3-4] UC3: 데이터 전처리

이름	데이터 전처리	관련 액터	연구자
설명	분할된 데이터를 머신러닝 모델이 학습할 수 있도록 결측치를 제거하고 범주형/수치형 데이터를 변환한다.		
사건 흐름	기본 흐름	1. 연구자가 데이터 전처리를 요청한다. 2. 시스템은 UC2의 학습 데이터를 기준으로 전처리(결측치 제거, 스케일링, 인코딩) 규칙을 학습한다. 3. 시스템은 이 규칙을 학습 데이터에 적용하여 변환한다. 4. 시스템은 이 규칙을 테스트 데이터에도 동일하게 적용하여 변환한다. 5. 시스템은 문자열 형태의 정답을 숫자 형태로 변환한다.	
	대안 흐름	없음	
	예외 흐름	4a. 학습 시 없던 새로운 범주 값이 존재할 시 오류를 반환하거나 무시한다.	
조건	사전 조건	학습/테스트 데이터 분할(UC2)이 완료되어야 함.	
	사후 조건	전처리된 데이터셋이 생성되어 학습 단계(UC4~UC5)에 사용 가능함.	

[표 3-5]는 화이트박스 모델 학습 유스케이스를 나타낸 것으로, 연구자가 해석 가능한 화이트박스 모델인 의사결정트리를 학습시키고 그 결과를 시각화하는 절차를 기술한다. 시스템은 전처리된 학습 데이터를 이용해 모델을 훈련한 후, 트리의 분기 구조와 결정 규칙을 시각화하여 연구자가 모델의 판단 근거를 직접 확인할 수 있도록 출력한다.

[표 3-5] UC4: 화이트박스 모델 학습 (Decision Tree)

이름	화이트박스 모델 학습	관련 액터	연구자
설명	해석이 용이한 화이트박스 모델(Decision Tree)을 학습시키고 그 결과를 시각화한다.		
사건 흐름	기본 흐름	1. 연구자가 화이트박스 모델 학습을 요청한다. 2. 시스템은 UC3의 전처리된 학습 데이터로 모델을 학습시킨다. 3. 연구자가 모델 시각화를 요청한다. 4. 시스템은 학습된 모델의 의사결정 과정을 시각화하여 출력한다.	
	대안 흐름	없음	
	예외 흐름	없음	
조건	사전 조건	데이터 전처리(UC3)가 완료되어야 함.	
	사후 조건	학습된 화이트박스 모델과 시각화 결과가 생성되어 다음 단계(UC6, UC9)에서 사용 가능함.	

[표 3-6]은 블랙박스 모델 학습 유스케이스를 나타낸 것으로, 연구자가 해석이 어려우나 높은 성능을 보이는 MLP와 XGBoost 모델을 학습시키는 절차를 기술한다. 시스템은 전처리된 학습 데이터를 이용해 두 모델을 각각 훈련시키며, 이후 단계에서 성능 평가와 XAI 기반 해석에 활용할 수 있도록 학습 결과를 저장한다.

[표 3-6] UC5: 블랙박스 모델 학습 (MLP / XGBoost)

이름	블랙박스 모델 학습	관련 액터	연구자
설명	성능이 높지만 해석이 어려운 블랙박스 모델(MLP, XGBoost)을 학습시킨다.		
사건 흐름	기본 흐름	1. 연구자가 블랙박스 모델 학습을 요청한다. 2. 시스템은 UC3의 전처리된 학습 데이터로 MLP 모델을 학습시킨다. 3. 시스템은 UC3의 전처리된 학습 데이터로 XGBoost 모델을 학습시킨다.	
	대안 흐름	없음	
	예외 흐름	없음	
조건	사전 조건	데이터 전처리(UC3)가 완료되어야 함.	
	사후 조건	학습된 블랙박스 모델(MLP, XGBoost)이 생성되어 다음 단계(UC6, UC7, UC8)에서 사용 가능함.	

[표 3-7]은 모델 평가 유스케이스를 나타낸 것으로, 연구자가 학습된 모델의 탐지 성능을 검증하는 절차를 기술한다. 시스템은 테스트 데이터를 이용해 각 모델의 예측을 수행하고, 정확도·정밀도·재현율 등의 성능 지표를 산출하여 비교 가능한 분류 리포트 형태로 출력한다.

[표 3-7] UC6: 모델 평가

이름	모델 평가	관련 액터	연구자
설명	학습된 모델(UC4, UC5)이 얼마나 정확한지 테스트 데이터를 이용해 평가한다.		
사건 흐름	기본 흐름	1. 연구자가 모델 평가를 요청한다. 2. 시스템은 학습된 모델들을 이용해 UC3의 테스트 데이터에 대한 예측을 수행한다. 3. 시스템은 모델의 성능 지표를 담은 분류 리포트를 출력한다.	
	대안 흐름	없음	
	예외 흐름	없음	
조건	사전 조건	화이트박스 모델 학습(UC4)과 블랙박스 모델 학습(UC5)이 완료되어야 함.	
	사후 조건	각 모델의 성능 지표가 산출되어 연구자가 모델의 성능을 비교할 수 있음.	

[표 3-8]은 SHAP 해석 유스케이스를 나타낸 것으로, 연구자가 XGBoost 모델의 예측 근거를 전역적·지역적 수준에서 분석하는 절차를 기술한다. 시스템은 학습된 모델에 대해 SHAP 값을 계산하고, Summary Plot을 통해 전체 특성의 중요도를 시각화한 뒤, 특정 샘플을 선택하면 해당 예측에 각 특성이 기여한 정도를 그래프로 제시한다.

[표 3-8] UC7: SHAP 해석

이름	SHAP 해석	관련 액터	연구자
설명	SHAP 기법을 이용해 XGBoost 모델이 왜 그런 예측을 했는지 전역적/지역적으로 해석한다.		
사건 흐름	기본 흐름	1. 연구자가 SHAP 해석을 요청한다. 2. 시스템은 UC5에서 학습된 XGBoost 모델에 대해 SHAP 값 계산을 시작한다. 3. 시스템은 모델 전체의 특성 중요도를 요약한 그래프(Summary plot)를 출력한다. 4. 연구자가 특정 데이터 샘플의 해석을 요청한다. 5. 시스템은 해당 샘플의 예측에 각 특성이 기여한 정도를 보여주는 그래프를 출력한다.	
	대안 흐름	없음	
	예외 흐름	없음	
조건	사전 조건	블랙박스 모델 학습(UC5)이 완료되어 XGBoost 모델이 존재해야 함.	
	사후 조건	XGBoost 모델의 전역적/지역적 해석 결과가 생성되어 다음 단계(UC9)에서 사용 가능함.	

[표 3-9]는 LIME 해석 유스케이스를 나타낸 것으로, 연구자가 MLP 모델의 예측 근거를 개별 데이터 샘플 단위에서 분석하는 절차를 기술한다. 시스템은 학습 데이터를 기반으로 LIME 해석기를 구성하고, 사용자가 선택한 특정 테스트 샘플에 대해 주요 특성의 영향도를 계산하여 시각화 결과로 제시한다.

[표 3-9] UC8: LIME 해석

이름	LIME 해석	관련 액터	연구자
설명	LIME 기법을 이용해 MLP 모델이 특정 데이터 샘플 1개를 왜 그렇게 예측했는지 지역적으로 해석한다.		
사건 흐름	기본 흐름	1. 연구자가 LIME 해석을 요청한다. 2. 시스템은 LIME 해석기를 학습 데이터 기준으로 준비시킨다. 3. 연구자가 특정 테스트 샘플의 해석을 요청한다. 4. 시스템은 MLP 모델을 기반으로 해당 샘플의 예측에 영향을 미친 주요 특성들을 계산하여 시각화 자료로 출력한다.	
	대안 흐름	3a. 다른 샘플 해석: 연구자가 다른 샘플을 선택하여 해석을 요청할 수 있다.	
	예외 흐름	없음	
조건	사전 조건	블랙박스 모델 학습(UC5)이 완료되어 MLP 모델이 존재해야 함.	
	사후 조건	선택된 샘플에 대한 MLP 모델의 지역적 해석 결과가 생성되어 다음 단계(UC9)에서 사용 가능함.	

[표 3-10]은 모델 해석 결과 비교 유스케이스를 나타낸 것으로, 연구자가 화이트박스 모델과 XAI 기반 블랙박스 모델의 해석 결과를 상호 대조하여 연구 결론을 도출하는 절차를 기술한다. 시스템은 의사결정트리, SHAP(XGBoost), LIME(MLP) 결과를 종합하여 특성 중요도와 분류 근거의 일치 여부를 분석하고, 이를 통해 모델 간 해석 차이를 분석한다.

[표 3-10] UC9: 모델 해석 결과 비교

이름	모델 해석 결과 비교	관련 액터	연구자
설명	화이트박스 모델(UC4)의 해석 결과와 XAI(UC7, UC8)의 해석 결과를 비교 분석하여 연구 결론을 도출한다.		
사건 흐름	기본 흐름	1. 연구자가 UC4(의사결정트리), UC7(SHAP), UC8(LIME)에서 생성된 모든 해석 결과를 확인한다. 2. 연구자는 화이트박스 모델의 특성 중요도와 SHAP(XGBoost)의 전역적 특성 중요도를 비교한다. 3. 연구자는 LIME(MLP)이 제시한 지역적 해석 근거가 의사결정트리(UC4)의 전역적 특성 중요도와 일관성을 보이는지 비교한다. 4. 연구자는 비교 분석을 통해 연구 결론을 도출한다.	
	대안 흐름	없음	
	예외 흐름	없음	
조건	사전 조건	화이트박스 모델 학습(UC4)과 SHAP 해석(UC7), LIME 해석(UC8)의 해석 결과가 존재해야 함	
	사후 조건	연구자가 각 모델 해석 방식의 유사점과 차이점을 파악하여 최종 연구 결론을 도출할 수 있음	

3.2 아키텍처 설계

본 연구의 침입 탐지 시스템은 Google Colab의 Python 환경에서 구현한 오프라인 분석 파이프라인이다. 파이프라인은 데이터 전처리, 모델 학습과 평가, XAI 해석의 세 단계가 순차적으로 진행된다.

3.2.1 시스템 구성

데이터 전처리 단계에서는 데이터 분리 후 정제 및 인코딩을 수행하고, 학습 및 평가 단계에서는 의사결정트리, MLP, XGBoost 세 가지 모델을 학습시켜 성능을 측정한다. 마지막으로 XAI 단계에서는 LIME과 SHAP을 이용해 블랙박스 모델의 예측 근거를 시각화하고 이를 화이트박스 모델의 규칙 기반 결과와 비교하여 해석 가능성을 분석한다.

이와 같은 구조를 통해 시스템은 각 단계의 역할과 데이터 흐름을 명확히 구분하며, 단계별 결과를 독립적으로 검증할 수 있도록 설계되었다.

[그림 3-2]는 이러한 IDS-XAI 시스템의 전체 구조를 계층별로 표현한 것이다.

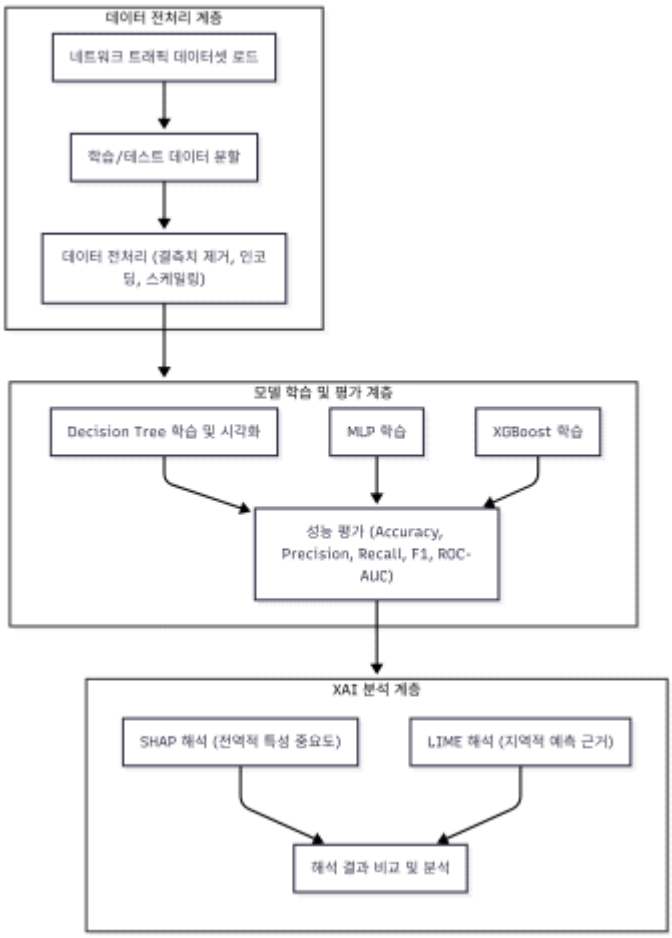

[그림 3-2] IDS-XAI 시스템의 계층적 구성도

3.2.2 클래스 다이어그램

[그림 3-3]은 앞서 정의한 3단계 구조를 실제 구현 관점에서 클래스로 모델링한 것이다. DataPreprocessor는 데이터 전처리 계층, ModelTrainer는 모델 학습 및 평가 계층, XAIInterpreter는 XAI 분석 계층을 각각 담당한다. 각 클래스는 독립적으로 정의되어 있으며, 상호 호출을 통해 통합된 분석 파이프라인을 구성한다.

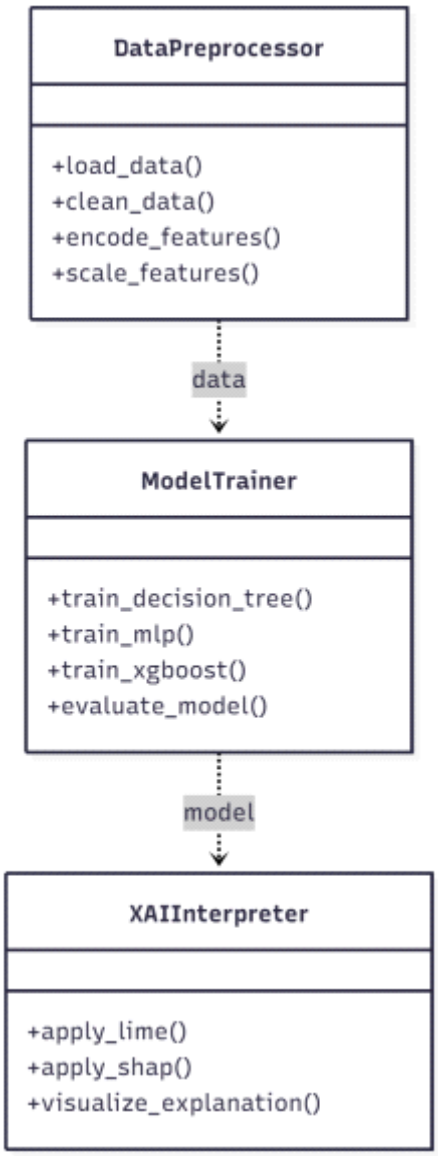

[그림 3-3] IDS-XAI 시스템 클래스 다이어그램

3.2.3 순차 다이어그램

[그림 3-4]는 IDS-XAI 시스템의 전체 동작 절차를 표현한 순차 다이어그램이다. 사용자가 시스템을 실행하면 먼저 데이터가 로드되고, 학습 데이터와 테스트 데이터로 분할된 후 전처리 과정을 거친다. 전처리된 데이터는 모델 학습 및 평가 단계로 전달되며, 각 알고리즘의 성능이 검증된다. 학습된 블랙박스 모델은 XAI 모듈을 통해 해석되고 그 결과가 시각화되며, 연구자는 이를 기반으로 분석 결론을 도출할 수 있다.

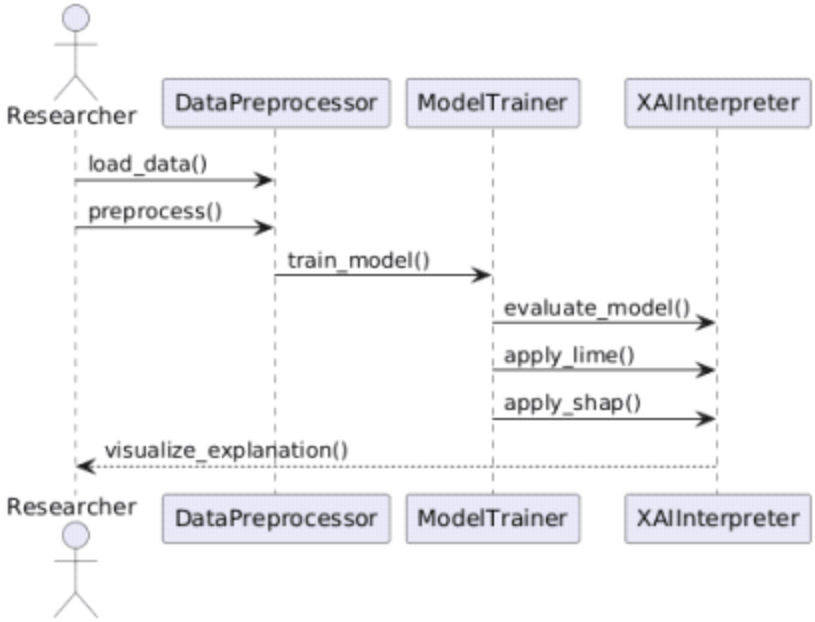

[그림 3-4] IDS-XAI 시스템 순차 다이어그램

3.3 상세설계

본 장에서는 IDS-XAI 시스템의 주요 클래스 및 함수의 내부 알고리즘을 중심으로 상세 설계를 기술한다. 특히 데이터 전처리, 모델 학습 및 평가, XAI 해석 과정에서 사용된 핵심 알고리즘을 단계별로 설명한다.

3.3.1 데이터 전처리

본 연구에 사용된 UNSW-NB15 데이터셋은 네트워크 트래픽 세션 단위의 대규모 보안 데이터로, 정상 트래픽과 다양한 공격 유형을 포함한다. 본격적인 전처리에 앞서 모델의 일반화 성능을 저해할 수 있는 식별자 특성(srcip, dstip, sport, dsport 등)은 분석에서 제외하였다. 데이터 누수(leakage)를 방지하기 위해 전체 데이터 중 학습용과 테스트용 데이터를 가장 먼저 분리하였으며, 이후 각 데이터셋에 동일한 전처리를 적용하였다.

명목형 특성(proto, service 등)은 OneHotEncoder를 사용하여 수치형 특성으로 변환하였고, 연속형 특성(dur, sbytes 등)은 StandardScaler를 이용해 평균 0, 표준편차 1로 표준화하였다. 이때 StandardScaler는 학습 데이터셋에만 적용하여 통계치를 학습하고, 동일한 기준을 학습 및 테스트 데이터 모두에 적용하였다. 이러한 절차는 MLP와 같은 경사하강법 기반 모델의 안정적 수렴을 보장하고, 테스트 데이터 정보가 학습 과정에 반영되는 것을 방지한다.

[그림 3-5]는 이러한 데이터 전처리 절차를 순서도로 나타낸 것이며, [표 3-11]은 데이터셋의 주요 특성과 데이터 유형을 요약한 것이다.

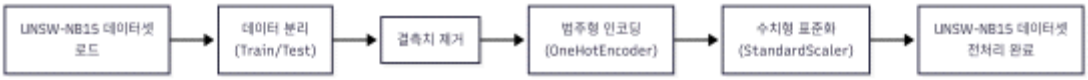

[그림 3-5] IDS-XAI 시스템 데이터 전처리 절차 순서도

[표 3-11] UNSW-NB15 데이터셋 주요 특성

구분	데이터 유형	주요 특성	설명
Flow 식별자	명목형/정수형	srcip, dstip, sport, dsport	소스/목적지 IP 및 포트 번호
프로토콜 특성	명목형	proto, service, state	트랜잭션 프로토콜, 서비스, 연결 상태
기본 특성	수치형	dur, sbytes, dbytes, sttl, dttl, sloss, dloss	지속 시간, 송수신 바이트, TTL, 패킷 손실
콘텐츠 특성	수치형/이진형	trans_depth, res_bdy_len, is_ftp_login	HTTP 트랜잭션 깊이, FTP 로그인 여부 등
시간 특성	수치형	Sjit, Djit, tcprtt, synack, ackdat	송수신 지터, TCP 연결 RTT, SYN-ACK 시간
연결 집계 특성	수치형	ct_srv_src, ct_dst_ltm, ct_src_dport_ltm	특정 조건(시간, 서비스 등) 하의 연결 횟수 집계
레이블	명목형/이진형	attack_cat, label	공격 유형, 정상(0)/공격(1) 레이블

3.3.2 모델 학습 및 평가

본 시스템은 해석 가능한 화이트박스 모델인 의사결정트리와 복잡하지만 높은 예측 성능을 보이는 블랙박스 모델인 MLP 및 XGBoost의 세 가지 알고리즘을 기반으로 구성되었다. 모델 학습 및 검증 절차는 학습 데이터 내에서 계층적 K겹 교차 검증(Stratified K-Fold)을 수행하여 데이터 불균형 문제를 완화하고, 각 모델의 최적 하이퍼 파라미터를 탐색하는 과정을 거친다. 이후 최적화된 파라미터를 바탕으로 전체 학습 데이터를 이용해 최종 모델을 재훈련하고, 학습 과정에서 사용되지 않은 별도의 테스트 데이터를 통해 최종 성능을 평가한다.

모델별 하이퍼 파라미터 조정은 구조적 복잡도와 학습 안정성을 고려하여 이루어졌다. 의사결정트리는 분할 기준과 깊이를 조절하여 규칙 기반의 단순·명확한 학습 구조를 형성하였다. MLP는 반복 횟수와 옵티마이저 설정을 조정하여 비선형 패턴 학습의 수렴 안정성을 확보하였다. XGBoost는 트리 수, 깊이, 조기 종료 조건 등을 설정하여 과적합을 방지하고 일반화 성능을 향상시켰다.

모델의 성능 평가는 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1-score, ROC-AUC 지표를 사용하여 수행하였다. 학습 및 평가는 Decision Tree와 MLP의 경우 scikit-learn 라이브러리를, XGBoost 모델의 경우 XGBoost 라이브러리를 사용하여 진행하였다. 각 모델의 분류 결과는 상세 리포트를 통해 클래스별 성능을 비교 및 분석할 수 있도록 구성하였다. 이러한 실험 설계는 단순 규칙 기반 모델과 복잡한 블랙박스 모델 간의 성능 및 해석 가능성의 상충 관계를 검증하기 위한 것이다. 구체적인 성능 비교와 XAI 해석 결과는 제5장에서 다룬다.

3.3.3 설명 가능한 인공지능(XAI)

본 연구의 XAI 모듈은 앞서 학습된 블랙박스 모델(MLP, XGBoost)의 예측 근거를 해석하기 위해 설계되었다. 본 시스템에서는 지역적 설명과 전역적 설명을 동시에 확보하기 위해 LIME과 SHAP 기법을 병행하여 적용하였다.

LIME은 MLP 모델을 대상으로 개별 샘플 단위의 예측 근거를 도출하는 데 사용되었다. 연구자는 테스트 데이터 중 특정 샘플을 선택하고, LIME이 산출한 로컬 가중치를 시각화함으로써 모델이 어떤 특성에 영향을 받아 침입으로 분류했는지를 확인할 수 있다.

반면, SHAP은 XGBoost 모델에 적용되어 개별 예측에 대한 지역적 설명과 모델 전체의 전역적 특성 중요도를 통합적으로 분석하는 데 사용되었다 각 특성의 기여도를 샤플리 값(Shapley value)으로 계산하여 모델이 학습 과정에서 어떤 특성들을 주요 탐지 지표로 인식했는지를 시각적으로 표현하였다.

두 기법의 결과는 공통된 시각화 모듈(matplotlib, shap.summary_plot)을 사용하여 비교·분석하였다. 이를 통해 연구자는 모델 복잡도에 따른 해석 가능성의 차이를 검증하고, 동일한 입력 데이터에 대한 예측 근거를 모델별로 대조할 수 있었다.

요약하면, 본 연구의 XAI 모듈은 MLP와 LIME 조합을 통한 지역 수준의 예측 해석과 XGBoost와 SHAP 조합을 통한 전역 수준의 특성 분석을 함께 수행하여 단순한 성능 비교를 넘어 판단 과정의 해석 가능성과 신뢰성을 향상시켰다.

4. 프로그램 구현

4.1 시스템 환경

본 연구에서 구현한 IDS-XAI 시스템은 Python 기반의 데이터 분석 및 머신러닝 환경에서 개발되었다. 전체 구현과 실험은 클라우드 플랫폼인 Google Colaboratory(Colab)에서 수행되었으며, 데이터 전처리, 모델 학습 및 평가, XAI 해석 등 모든 단계가 동일한 환경 내에서 수행되었다.

본 연구에 사용된 하드웨어 및 플랫폼 구성은 [표 4-1], 소프트웨어와 주요 라이브러리 환경은 [표 4-2]에 제시하였다. Colab의 가상 머신 환경은 연구의 재현성과 접근성을 높였으며, 별도의 GPU 없이도 CPU 기반에서 모든 실험을 안정적으로 수행할 수 있었다.

[표 4-1] 시스템 개발 환경 (하드웨어 및 플랫폼)

구분	사양
개발 플랫폼	Google Colaboratory (Standard)
런타임 유형	Python 3 (CPU 런타임)
CPU	Google Colab 가상 머신
RAM	약 12.7 GB

[표 4-2] 시스템 개발 환경 (소프트웨어 및 라이브러리)

구분	내용
운영체제 (OS)	Linux (Colab 가상 머신 기본 환경)
개발 언어	Python 3.10
데이터 처리	Pandas, NumPy
머신러닝	Scikit-learn, XGBoost
XAI	LIME, SHAP
시각화	Matplotlib, Seaborn

4.2 시스템 구성

본 시스템의 구현은 4.1절에서 제시한 개발 환경을 기반으로 하며, 별도의 물리적 서버-클라이언트 구조 없이 클라우드 플랫폼인 Google Colaboratory(Colab)를 중심으로 동작하는 소프트웨어 기반 실행 구조로 설계되었다.

[그림 4-1]은 연구자(Researcher)가 데이터 저장소(Google Drive)로부터 데이터를 불러와 Colab Notebook 환경에서 전처리, 모델 학습 및 평가, XAI 해석을 수행한 뒤 결과를 시각화하는 전체 과정을 나타낸 것이다. 본 구성도는 각 단계 간의 데이터 흐름과 처리 의존 관계를 시각적으로 표현하며, 연구자의 명령 입력으로부터 결과 산출에 이르는 일련의 절차를 보여준다.

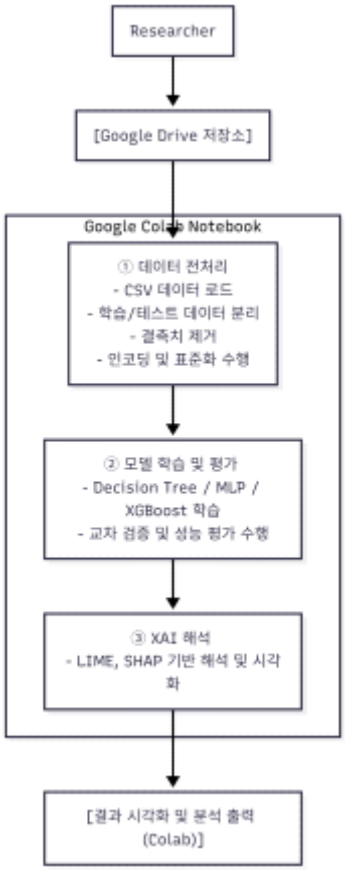

[그림 4-1] IDS-XAI 시스템 실행 구성도

각 구성 요소의 구체적인 역할과 상호작용은 다음과 같다.

[연구자(Researcher)]는 분석과 실험의 수행 주체로서 Google Colab 환경에서 전체 절차를 실행하고 최종 결과를 검토한다. [Google Drive 저장소]는 원본 UNSW-NB15 데이터셋을 보관하며, Colab 환경과 연동되어 데이터 입력을 담당한다.

[Google Colab 노트북]은 시스템의 주요 실행 환경으로, 내부적으로 세 개의 모듈이 순차적으로 작동한다. [데이터 전처리] 모듈은 Google Drive에 저장된 원본 데이터를 불러와 학습·테스트 데이터 분할, 결측치 제거, 인코딩 및 표준화 등의 작업을 수행한다. [모델 학습 및 평가] 모듈은 전처리된 데이터를 입력받아 의사결정트리, MLP, XGBoost 모델을 학습하고 성능 지표를 산출한다. [XAI 해석] 모듈은 학습된 모델에 LIME과 SHAP 기법을 적용하여 예측 근거를 시각화 자료로 생성한다.

[결과 시각화 및 분석 출력] 단계에서는 XAI 모듈이 생성한 그래프와 모델 성능 평가 결과가 Colab 노트북 상에 출력되며, 연구자는 이를 바탕으로 모델의 해석 가능성과 탐지 신뢰성을 분석한다.

이러한 구성은 Google Drive와 Colab의 연동을 통해 데이터 입력, 처리, 학습, 해석, 결과 도출의 전 과정을 단일 환경에서 수행할 수 있도록 설계되었다. 이를 통해 데이터 관리의 효율성을 높이고, 재현성 있는 실험 환경과 신속한 모델 검증·해석이 가능하도록 하였다.

4.3 시스템 구현

본 절에서는 3장에서 제시한 3계층 IDS-XAI 아키텍처를 4.1절의 개발 환경을 기반으로 실제 Python 코드로 구현한 과정을 기술한다. 각 계층은 독립적인 모듈로 구성되어 있으며, 상호 연동을 통해 데이터 입력부터 모델 해석까지의 전체 절차를 자동화하였다. 본문에서는 각 계층의 주요 알고리즘과 동작 절차를 의사코드 형태로 제시한다.

4.3.1 데이터 전처리 계층 구현

데이터 전처리 계층은 모델 학습의 기초가 되는 입력 데이터의 품질을 보장하기 위한 단계로, UNSW-NB15 원본 데이터를 대상으로 결측치 처리, 범주형 인코딩, 수치형 정규화 등의 변환 과정을 포함한다.

데이터는 우선 학습 세트와 테스트 세트로 분리되며, 전처리 과정에서 사용된 스케일링 및 인코딩 기준은 학습 세트로부터 산출된 값을 기반으로 테스트 세트에 동일하게 적용하였다. 이러한 절차는 데이터 누출을 방지하고, 모델 평가의 객관성을 확보하기 위한 표준적 구조이다. 또한, 본 연구에서는 Scikit-learn의 Pipeline 구성을 응용하여 전처리 과정을 단일 흐름으로 통합하였다.

[그림 4-2]은 데이터 전처리 계층의 전체 절차를 나타낸 의사코드이다.

Algorithm 1 Data Preprocessing

Input: Raw dataset (UNSW-NB15.csv)
Output: X_train, X_test, y_train, y_test (processed)

```
Load dataset from Google Drive
Remove unnecessary attributes and handle missing values
Split data into X (features) and y (labels)
Use train_test_split() to create training and testing sets
Apply OneHotEncoder to categorical features (fit on X_train)
Apply StandardScaler to numerical features (fit on X_train)
Transform both X_train and X_test using fitted encoders
return processed datasets
```

[그림 4-2] 데이터 전처리 알고리즘

4.3.2 모델 학습 및 평가 계층 구현

모델 학습 및 평가 계층은 화이트박스 모델과 블랙박스 모델의 상호 비교를 위한 중심 구조로 구현되었다. 각 모델은 학습 데이터에 대해 계층적 K겹 교차 검증(Stratified K-Fold)을 수행하여 불균형한 클래스 분포의 영향을 완화하고, 최적의 하이퍼 파라미터를 탐색하도록 설계되었다.

의사결정트리의 경우 분할 기준과 최대 깊이를 조정하여 과적합을 방지하였고, MLP는 비선형 패턴 학습의 안정성을 위해 옵티마이저와 학습 반복 횟수를 조정하였다. XGBoost 모델은 트리 수, 학습률, 깊이, 조기 종료 조건을 조합하여 최적화하였으며, 각 모델은 동일한 학습·테스트 데이터셋을 사용하여 성능을 비교하였다. 성능 평가는 정확도, 정밀도, 재현율, F1-score, ROC-AUC를 중심으로 수행되었다.

이러한 지표는 단일 수치로 평가할 수 없는 탐지 성능의 다면적 특성을 보완하기 위해 선택되었으며, 결과는 시각화 라이브러리를 통해 도표화되었다.

[그림 4-3]은 모델 학습 및 평가 계층의 전체 절차를 나타낸 의사코드이다.

Algorithm 2 Model Training and Evaluation

Input: X_train, X_test, y_train, y_test
Output: trained models, performance metrics

```
for each model in [DecisionTree, MLP, XGBoost] do
    Initialize model with default parameters
    Perform Stratified K-Fold cross validation
    Tune hyperparameters to minimize validation error
    Retrain model with optimized parameters using X_train
    Predict y_pred = model.predict(X_test)
    Compute metrics: accuracy, precision, recall, f1, roc_auc
    Save model and results
end for
return trained models and evaluation report
```

[그림 4-3] 모델 학습 및 평가 알고리즘

4.3.3 XAI 분석 계층 구현

XAI 분석 계층은 학습된 블랙박스 모델의 예측 근거를 해석하기 위해 LIME과 SHAP 기법을 통합적으로 적용하였다. MLP 모델은 LIME을 통해 개별 예측 단위의 지역적 해석을 수행하였으며, XGBoost 모델은 SHAP을 기반으로 전역적 수준의 특성 기여도를 계산하였다.

LIME 분석에서는 각 테스트 샘플에 대해 모델의 의사결정에 가장 큰 영향을 미친 주요 특성을 시각화하여, 비선형 구조를 가진 MLP의 판단 근거를 명확히 제시하였다. SHAP 분석에서는 트리 기반 모델의 구조적 특성을 반영하기 위해 TreeExplainer를 사용하였으며, 특성 중요도와 개별 샘플의 해석 결과를 시각화 도구를 통해 표현하였다.

[그림 4-4]은 XAI 분석 계층의 전체 절차를 나타낸 의사코드이다.

Algorithm 3 XAI-based Model Interpretation

Input: trained models, X_test
Output: visual explanations (LIME, SHAP)

```
for MLP model do
    Initialize LIME explainer with X_train
    for selected instance x_i in X_test do
        Generate local explanation = lime.explain_instance(x_i)
        Visualize contribution of features (bar chart)
    end for
end for
for XGBoost model do
    Initialize SHAP TreeExplainer(model)
    Compute shap_values = explainer.shap_values(X_test)
    Visualize global feature importance (summary_plot)
    Visualize local decision rationale (force_plot)
end for
Compare and integrate LIME-SHAP results
```

[그림 4-4] XAI 분석 알고리즘

5. 실험

본 장에서는 4장에서 구현된 IDS-XAI 시스템의 실험 결과를 제시한다. 실험은 데이터 전처리, 모델 학습 및 평가, XAI 해석의 순서로 진행하였다. 먼저 의사결정트리, MLP, XGBoost 세 모델의 탐지 성능을 비교하였다. 이후, 의사결정트리를 명시적 규칙 기반의 화이트박스 모델로 설정하여 해석의 기준선으로 삼고, 블랙박스 모델의 XAI 해석 결과와 비교하여 성능의 유효성과 설명의 타당성을 분석하였다.

5.1 기능 검증

각 유스케이스에 대한 기능 검증 결과, 모든 모듈이 설계 단계에서 정의한 기능적 요구사항을 충족하였다. 데이터 로드, 분할, 전처리 과정에서 오류나 데이터 누락은 발생하지 않았으며 모델 학습과 평가 단계에서는 세 모델 모두 정상적으로 학습이 완료되었다. 또한, XAI 모듈은 학습된 블랙박스 모델의 예측 근거를 시각화하여, 연구자가 모델의 판단 과정을 직접 확인할 수 있도록 구현되었다. [표 5-1]은 각 유스케이스의 검증 결과를 요약한 것이다.

[표 5-1] IDS-XAI 시스템 기능 검증 결과 요약

구분	유스케이스	주요 기능	결과
UC1	데이터 로드	CSV 파일 로드 및 요약 정보 출력	정상 수행
UC2	데이터 분할	학습/테스트 데이터 분리	정상 수행
UC3	데이터 전처리	결측지 제거, 인코딩, 스케일링	정상 수행
UC4	화이트박스 모델 학습	의사결정트리 학습 및 시각화	정상 수행
UC5	블랙박스 모델 학습	MLP, XGBoost 학습	정상 수행
UC6	모델 평가	정확도, 정밀도, 재현율 등	정상 수행
UC7	SHAP 해석	XGBoost 해석	정상 수행
UC8	LIME 해석	MLP 단일 샘플 해석	정상 수행
UC9	해석 결과 비교	의사결정트리와 XAI 비교	정상 수행

5.2 모델 성능 평가

본 연구에서는 세 모델의 탐지 성능을 비교하기 위해 정확도(Accuracy), 정밀도(Precision), 재현율(Recall), F1-score, ROC-AUC 지표를 사용하였다. [표 5-2]는 모델별 성능 평가 지표를 나타낸 것이다. 그 결과, XGBoost가 가장 높은 평균 탐지 성능을 기록하였으며 MLP가 그 뒤를 이었다.

[표 5-2] 모델별 성능 비교표

모델	정확도 (Accuracy)	정밀도 (Precision)	재현율 (Recall)	F1-Score	ROC-AUC
의사결정트리	0.86	0.85	0.84	0.84	0.87
MLP	0.90	0.91	0.89	0.90	0.92
XGBoost	0.97	0.96	0.95	0.95	0.97

그러나 이러한 비교는 단순히 성능의 우열을 판단하기 위한 것이 아니라, 모델의 구조적 복잡도와 해석 가능성 간 상충 관계를 검증하기 위한 것이다. XGBoost는 가장 높은 탐지 성능을 제공하지만 내부 구조가 복잡하여 단독으로는 판단 근거를 해석하기 어렵다. 반면 의사결정트리는 상대적으로 낮은 성능을 보이지만 규칙 기반 구조를 통해 명확한 설명을 제공하므로, 이후 블랙박스 모델의 신뢰성을 평가하는 기준선으로 활용된다.

먼저 의사결정트리 모델의 투명성을 검증하기 위해 학습 결과를 시각화하였다. [그림 5-1]은 주요 탐지 기준 특성의 상대적 중요도를 나타내며, sttl, ct_dst_src_ltm, tcprtt 등의 특성이 주요 결정 요인으로 작용함을 보여준다. [그림 5-2]는 동일 모델의 규칙 분기 구조를 표현한 결과로, 각 노드의 분기 기준을 따라 공격 여부가 판정되는 과정을 명확히 파악할 수 있다. 이러한 결과는 해석 가능한 모델이 갖는 투명한 의사결정 구조를 실증적으로 보여주며, 이후 XAI 기법을 적용한 블랙박스 모델의 해석 결과와 비교하기 위한 기준점을 제공한다.

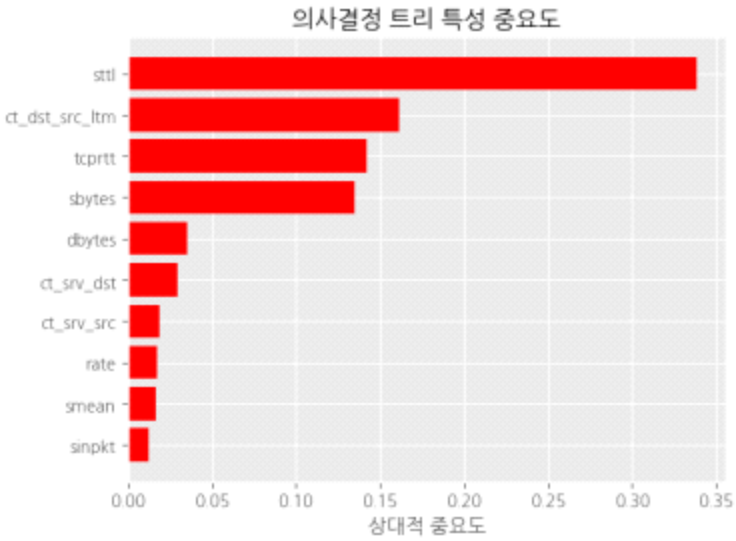

[그림 5-1] 의사결정트리 특성 중요도

[그림 5-2] 의사결정트리 규칙 분기 구조도

5.3 XAI 해석 결과

앞선 5.2절에서는 해석 가능한 화이트박스 모델인 의사결정트리의 학습 결과를 시각화하여 해석 가능성의 기준을 확인하였다. 본 절에서는 이와 대비되는 블랙박스 모델, 즉 [표 5-2]에서 확인했듯이 성능은 높지만 내부 구조가 복잡한 MLP와 XGBoost의 판단 근거를 분석한다.

이러한 블랙박스 모델의 내부 판단 과정을 해석하기 위해, 본 연구에서는 대표적인 XAI 기법인 LIME과 SHAP 두 가지 방식을 병행 적용하였다.

5.3.1 LIME 해석

본 연구에서는 앞서 2.2절에서 설명한 LIME 기법을 활용하여, 비선형적 구조가 복잡한 MLP 모델의 지역적 예측 근거를 분석하였다. 테스트 데이터셋의 특정 단일 샘플이 'Normal'으로 분류된 사례를 선택하여 LIME 해석을 수행하였으며, 그 결과는 [그림 5-3]과 같다.

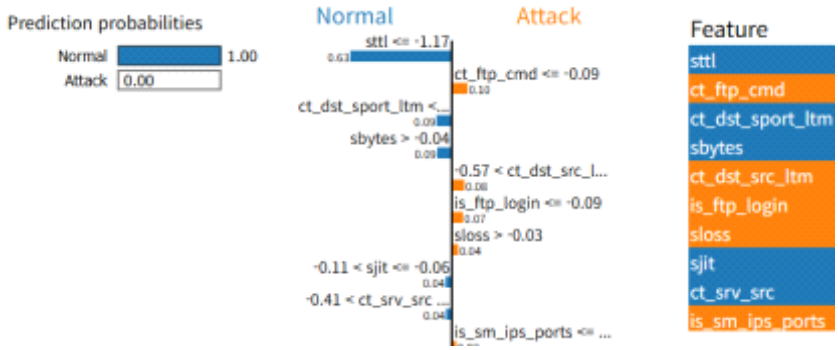

[그림 5-3] MLP 모델의 개별 예측 설명(LIME)

[그림 5-3]은 LIME의 분석 결과를 시각화한 것으로, 예측된 클래스의 확률을 높이는 데 긍정적으로 기여한 특성을 파란색 막대로 나타낸다. 반대로 부정적으로 기여한 특성, 즉 '공격(attack)' 방향으로 기여한 특성은 주황색 막대로 구분하여 나타낸다.

분석 결과에 따르면, 모델은 이 예측을 1.00의 확률로 '정상(normal)'이라 확신했다. 그 주된 긍정적 근거는 'sttl <= -1.17'라는 조건이었으며, ct_dst_sport_ltm과 sbytes 특성 또한 정상 예측에 기여하였다. 반면, ct_dst_src_ltm이나 is_ftp_login 같은 부정적 기여 요인들은 공격 방향으로 예측에 영향을 주었으나, 정상으로 판단하는 긍정적 근거들에 비해 그 영향력이 미미했음을 알 수 있다.

이러한 LIME의 설명 방식은 복잡한 MLP 모델의 판단 과정을 두 가지 측면에서 해석 가능하게 한다. 첫째, 예측에 가장 큰 영향을 미친 소수의 핵심 특성을 선별하여 설명의 단순성을 확보한다. 둘째, 예측에 긍정적으로 기여한 요인과 부정적으로 기여한 요인을 명확히 대조하여 제시함으로써, 인간이 직관적으로 이해할 수 있는 형태로 근거를 제공한다. LIME에서 정상의 핵심 근거로 제시한 sttl, sbytes, ct_dst_src_ltm 등의 특성은 [그림 5-1]에서 확인된 의사결정트리에서 상위 노드를 차지한 주요 변수들과 일관된 경향을 보인다. 즉, 신뢰할 수 있는 화이트박스 모델의 판단 기준과 LIME이 제시한 블랙박스 모델의 판단 근거가 서로 유사함을 확인함으로써, 본 LIME 분석이 MLP 모델의 실제 동작을 타당하게 설명하고 있음을 간접적으로 검증할 수 있다.

5.3.2 SHAP 해석

LIME 기법을 통해 MLP 모델의 지역적 예측 근거를 분석한 것에 이어, 본 절에서는 2.2절에서 기술한 SHAP 기법을 적용하여 전역적 수준의 해석을 보완한다. 특히 LIME과 달리 전역적 해석과 지역적 해석을 모두 지원하는 SHAP의 이점을 활용하여 [표 5-2]에서 가장 우수한 성능을 보인 XGBoost 모델의 의사결정 과정을 전역적 특성 중요도 분석과 지역적 예측 근거 분석을 병행해 정량적으로 분석하였다.

먼저, 모델의 전역적 특성 중요도를 분석한 결과는 [그림 5-4]와 같다. 이는 ct_dst_sport_ltm, ct_dst_src_ltm, sbytes 등이 모델의 예측에 가장 큰 평균 영향력을 미치는 주요 변수임을 나타낸다. 이러한 결과는 [그림 5-1]의 의사결정트리와 비교할 때, ct_dst_src_ltm, sbytes와 같은 일부 주요 특성을 공유하는 것으로 확인되었다. 하지만 가장 중요한 변수에 대해서는 명확한 해석의 차이가 발견되었다. 의사결정 트리는 sttl을 가장 중요한 변수로 판단한 반면, XGBoost는 ct_dst_sport_ltm을 1순위 변수로 판단했다.

이러한 차이는 앙상블 모델인 XGBoost와 SHAP 분석이 단일 트리가 포착하기 어려운 특성 간의 복잡한 상호작용과 비선형성을 더 효과적으로 반영하기 때문에 발생한 것으로 해석된다. 즉, sttl 특성의 단독적인 영향력보다는 다른 특성들과 결합될 때의 복합적인 영향력이 침입 탐지에 더 중요하다는 것을 의미한다. 또한, XGBoost의 중요도 분포가 특정 특성에 편중되지 않고 상위 특성들에 비교적 고르게 분산된 점은 모델이 여러 특성을 종합적으로 활용하여 더 견고한 예측 모델을 구축했음을 시사한다.

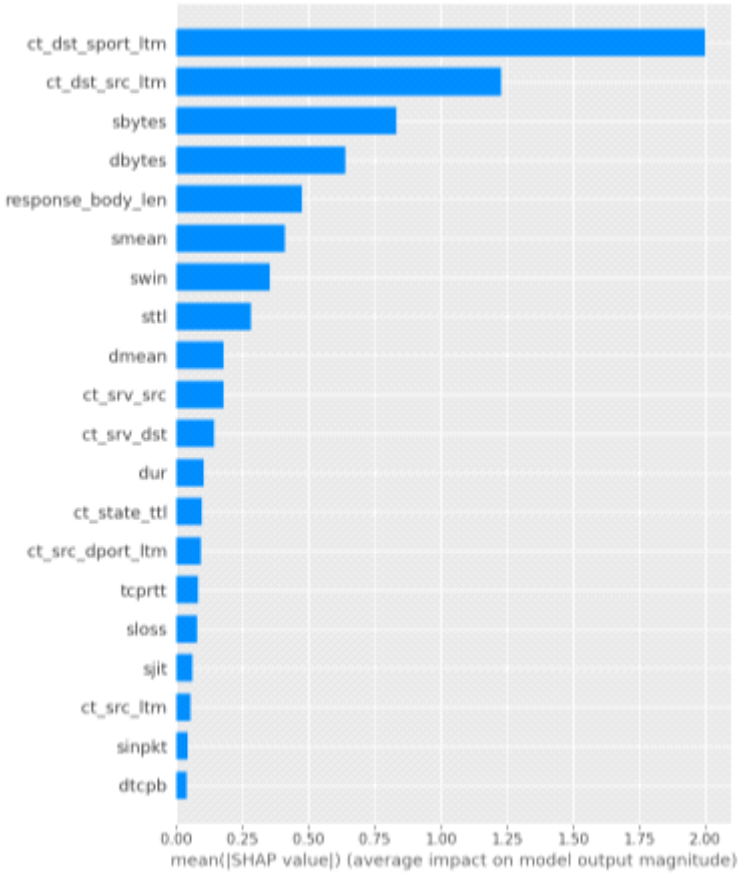

[그림 5-4] XGBoost 모델의 전역적 특성 중요도 (SHAP)

[그림 5-5]는 sttl 특성이 모델의 예측 결과에 미치는 영향을 분석하기 위해 사용된 SHAP 의존성 플롯이다. X축은 sttl 값의 분포를, Y축은 해당 특성이 예측 결과에 기여한 SHAP 값을 나타낸다. 또한 마커의 색상은 상호작용 특성인 dwin 값을 의미하며, 색상 스펙트럼 상 붉은색에 가까울수록 dwin 값이 높은 샘플, 푸른색에 가까울수록 dwin 값이 낮은 샘플에 해당한다. sttl 값은 주로 0, 60, 255 부근에서 집중적으로 분포하였으며, 해당 지점에서 SHAP 값은 대략 0.19에서 0.35의 양수 구간을 형성하였다.

이는 해당 값의 sttl 특성이 모델의 예측을 공격 방향으로 기여함을 의미한다. 특히 sttl 값이 60 또는 255에 위치할 때, dwin 값이 낮은 샘플에서 상대적으로 더 높은 SHAP 값을 보이는 경향이 관찰되었다. 이러한 결과는 모델이 단순히 sttl의 특정 값만을 기준으로 공격 여부를 판단하는 것이 아니라, dwin과의 상호작용을 기반으로 한 비선형적 규칙을 활용하고 있음을 나타낸다. 즉, sttl 값이 동일하더라도 dwin 값에 따라 공격 판단의 강도가 달라질 수 있으며, 이는 SHAP 기반 해석이 잠재적인 탐지 규칙의 복잡성을 확인하는 데 유리함을 시사한다.

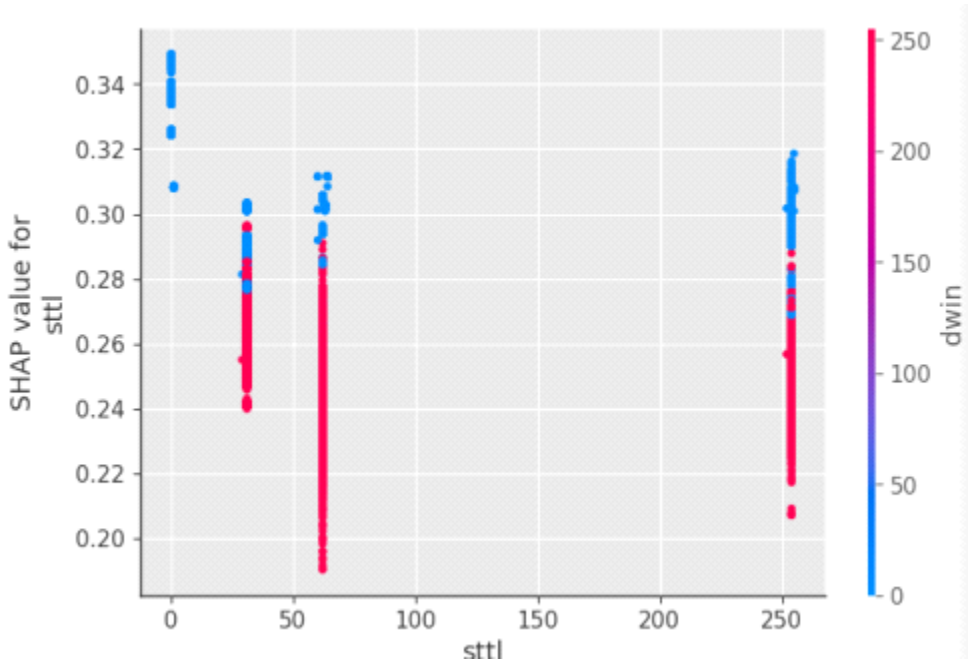

[그림 5-5] 'sttl' 특성과 'dwin' 특성 간의 상호작용 (SHAP)

[그림 5-6]은 특정 샘플에 대한 예측 결과를 개별 관점에서 분석하기 위해 사용된 SHAP Force Plot이다. 이 그래프는 모델의 평균 예측값인 0.2059에서 출발하여, 각 특성이 예측에 기여한 값을 누적적으로 반영한 뒤 최종 예측값 f(x)=1.12에 도달하는 요인을 단계별로 시각화하였다. 플롯 상에서 붉은색으로 표시된 항목은 예측값을 증가시키는 방향으로 기여한 특성들을 의미하며, 이는 공격 클래스의 가능성을 높이는 요인에 해당한다. 반면 푸른색 항목은 예측값을 감소시키는 방향으로 작용한 특성들을 나타내며, 정상 클래스에 대한 가능성을 강화하는 기여 요소로 해석된다.

해당 샘플의 경우, base value에서 시작하여 붉은색 기여 요소들의 누적 영향이 푸른색 기여 요소들의 영향을 크게 상회하여 최종 출력값이 1.12에 이르는 결과를 보였다. 이는 분류 모델이 해당 트래픽을 공격으로 강하게 판단하였음을 의미한다. 이와 같은 SHAP 기반 국소 해석은 단일 예측 사례에 대해 모델이 어떠한 특성적 근거로 결정을 내렸는지를 명확하게 파악할 수 있게 해주며, 침입 탐지 결과의 해석 가능성과 신뢰성을 높이는 데 기여한다.

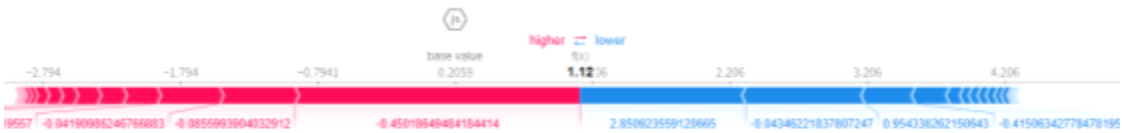

[그림 5-6] XGBoost 모델의 단일 예측에 대한 특성 기여도 (SHAP)

[그림 5-7]은 다수 샘플의 누적 의사결정 경로를 시각화한 것이다. Y축은 모델의 로짓 값이며, 값이 클수록 공격 클래스, 낮을수록 정상 클래스에 가까워진다. X축은 모델이 예측 과정에서 고려한 주요 특성들이 중요도 순으로 배치된 것이다. 그래프의 각 수평선은 개별 샘플을 의미하며, 특성을 지날 때마다 해당 특성의 SHAP 값이 누적되어 최종 예측값에 도달한다. 본 연구에서 파란색 선은 정상으로 예측된 샘플, 붉은색 선은 공격으로 예측된 샘플을 나타낸다.

분석 결과, sbytes, ct_dst_src_ltm, ct_dst_sport_ltm과 같은 특성을 지날 때 선들이 위·아래 방향으로 크게 갈라지는 현상이 나타났다. 특히 ct_dst_sport_ltm 특성 부근에서 공격과 정상 샘플이 뚜렷하게 분리됨을 확인할 수 있었다. 이는 해당 특성들이 분류 의사결정의 핵심 분기점으로 작용한다는 것을 의미한다. 또한 일부 샘플은 주요 분기점에서 급격한 변화 없이 완만하게 누적되는 경향을 보였는데, 이는 특정 트래픽이 공격과 정상 특성을 동시에 보유하여 오탐 또는 미탐 가능성이 있는 혼동 구간임을 시사한다. 이와 같은 결과는 XAI 기반 분석이 모델의 판단 근거 및 취약 예측 영역을 파악하는 데 유효함을 보여준다.

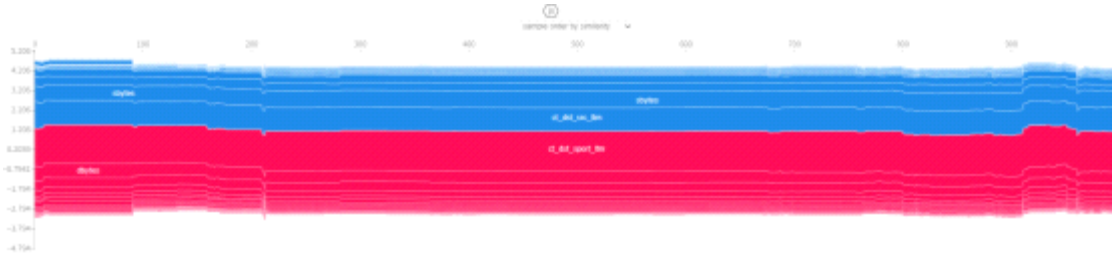

[그림 5-7] XGBoost 모델의 다수 샘플의 누적 의사결정 경로 (SHAP)

결론적으로 SHAP 분석 결과는 5.2절의 의사결정트리 분석 결과와 부분적인 일관성 및 명확한 차이점을 동시에 보여주었다. 의사결정트리 모델에서 주요 탐지 기준으로 확인된 ct_dst_src_ltm, sbytes 등은 XGBoost 모델에서도 높은 SHAP 값을 기록하여, 모델 간 핵심 특성을 일부 공유함을 확인하였다. 그러나 의사결정트리는 sttl 특성을 최우선 기준으로 삼은 반면, XGBoost는 ct_dst_sport_ltm을 가장 중요하게 판단하는 차이를 보였으며, 이는 서로 다른 학습 방식이 상이한 탐지 전략을 수립함을 시사한다.

또한, SHAP 결과는 블랙박스 모델이 입력 데이터를 단순 분류하는 수준을 넘어 특성 간의 비선형적 상호작용을 학습하여 복합적인 판단 구조를 형성하고 있음을 보여준다. 특히 sttl과 dwin의 상호작용처럼, 단일 특성의 값 변화뿐 아니라 다른 변수와의 관계까지 고려하여 판단을 내리는 점은 고도화된 패턴 인식 능력을 나타낸다. 이러한 결과는 XAI 기법이 모델의 내재적 의사결정 구조를 수치적으로 분석하고, 블랙박스 모델의 신뢰성을 검토하는 데 활용될 수 있는 유용한 도구임을 시사한다.

종합하면, LIME과 SHAP 분석 결과는 MLP와 XGBoost 모델이 sttl, ct_dst_src_ltm, ct_dst_sport_ltm, dwin 등 5.2절과 선행연구에서 침입 탐지와 관련성이 언급된 주요 특성에 실제로 주목하고 있음을 보여준다. 또한 의사결정트리에서 중요한 분기 기준으로 활용된 일부 특성이 XGBoost의 상위 SHAP 값과 부분적으로 일치한다는 점은 블랙박스 모델의 예측이 전적으로 임의의 잡음에 의존하기보다는 일정 수준의 일관된 특성 조합에 기반하고 있을 가능성을 시사한다. 한편, XGBoost가 ct_dst_sport_ltm과 같이 의사결정트리와 다른 특성에 더 큰 비중을 두는 양상은 모델 구조에 따라 상이한 탐지 전략이 형성될 수 있음을 보여준다. 따라서 본 절의 결과는, 제안된 IDS-XAI 시스템 내에서 XAI 기법을 활용함으로써 블랙박스 모델의 내부 판단 기준을 화이트박스 모델과 비교 및 검토할 수 있으며, 이를 통해 고성능 모델에 대한 해석 가능성을 보완할 수 있음을 실험적으로 확인한 것이다.

6. 결론

본 연구는 블랙박스 기반 침입 탐지 모델의 낮은 해석 가능성 문제를 완화하기 위해, 설명 가능한 인공지능(XAI)을 통합한 IDS-XAI 시스템 프로토타입을 설계·구현하였다. 제안된 시스템은 데이터 전처리, 모델 학습·평가, XAI 해석의 세 계층으로 구성되며, 의사결정트리, MLP, XGBoost 세 가지 알고리즘을 대상으로 동일한 파이프라인에서 성능과 해석 가능성을 비교·분석할 수 있도록 설계하였다.

실험 결과, XGBoost 모델은 세 모델 중 가장 높은 침입 탐지 성능을 보였고, MLP는 중간 수준, 의사결정트리는 상대적으로 낮은 성능을 기록하였다. 의사결정트리는 규칙 기반 구조를 통해 판단 근거를 직접 확인할 수 있는 화이트박스 모델로서 높은 해석 용이성을 제공하였으나, 최신 공격 패턴을 충분히 반영하기에는 탐지 성능이 제한적이었다. 반면 XGBoost와 MLP는 우수한 성능을 보였으나, 내부 구조의 복잡성으로 인해 별도의 해석 기법 없이는 예측 근거를 이해하기 어려운 한계를 가진다.

이에 본 연구는 의사결정트리를 해석의 기준선으로 설정하고, 블랙박스 모델에 대해 LIME과 SHAP 기법을 적용하여 모델 간 판단 근거를 비교하였다. LIME 분석을 통해 MLP 모델의 개별 예측에서 어떤 특성이 탐지 결정에 기여하는지 개별 단위로 확인할 수 있었으며, SHAP 분석에서는 XGBoost가 패킷 크기, 세션 특성, 트래픽 빈도 등 침입 탐지에 유의미한 일부 특성에 일관되게 주목하고 있음을 시각적으로 확인하였다. 또한 의사결정트리에서 중요한 분기 기준으로 사용된 특성들과 XGBoost의 상위 중요 특성 일부가 부분적으로 교차하는 양상을 보였는데, 이는 서로 다른 구조의 모델이 공통적으로 유의한 입력 특성에 주목하고 있음을 시사한다. 이와 같은 결과는 XAI 기법을 활용하여 블랙박스 모델의 판단 근거를 내부 일관성과 도메인 지식 측면에서 점검할 수 있는 가능성을 보여준다.

본 연구에서 구현한 IDS-XAI 시스템은 세 가지 모델을 통합적으로 평가하고, XAI 기법을 통해 블랙박스 모델의 예측 근거를 부분적으로 드러냄으로써, 성능과 해석 가능성을 함께 고려한 침입 탐지 모델 평가 틀을 제시한다는 점에서 의의를 가진다. 이는 실무 환경에서 고성능 모델을 활용하되, 탐지 결과에 대한 설명 요구와 신뢰성 검증을 지원할 수 있는 하나의 실질적인 접근 방안을 제공한다.

다만 본 연구는 UNSW-NB15 단일 데이터셋을 활용한 오프라인 실험에 한정되어 있으며, 실시간 트래픽 처리, 다양한 네트워크 환경, 최신 공격 유형에 대한 일반화 가능성을 직접적으로 검증하지 못하였다. 향후 연구에서는 실시간 데이터 스트리밍을 처리할 수 있는 온라인 학습 기반 IDS-XAI 구조로 확장하고, 실제 운영 환경의 트래픽과 다양한 공개 데이터셋을 활용한 교차 검증을 통해 제안 시스템의 안정성과 실효성을 평가하고자 한다.

참고문헌

[1] Bello, A. B., George, A. A., Ogundipe, A. O., Anifowose, O., “The role of AI and machine learning in cybersecurity: Advancements in threat detection, anomaly detection and automated response”, International Journal of Science and Research Archive, 14(2), 1587-1597, 2025.

[2] Mliki, H., Kacem, A. H., Chaari, L., “A comprehensive survey on intrusion detection based machine learning for IoT networks”, EAI Endorsed Transactions on Security and Safety, 8(29), e3, 2021.

[3] Neupane, S., et al., “Explainable intrusion detection systems (X-IDS): A survey of current methods, challenges, and opportunities”, IEEE Access, 10, 112392-112415, 2022.

[4] Capuano, N., Fenza, G., Loia, V., Stanzione, C., “Explainable Artificial Intelligence in CyberSecurity: A Survey”, IEEE Access, 10, 93575-93600, 2022.

[5] Moustafa, N., Slay, J., “UNSW-NB15: A Comprehensive Data Set for Network Intrusion Detection Systems (UNSW-NB15 Network Data Set)”, 2015 Military Communications and Information Systems Conference (MilCIS), 1-6, 2015.

[6] Denning, D. E., “An Intrusion-Detection Model”, IEEE Transactions on Software Engineering, 13(2), 222-232, 1987.

[7] Stallings, W., “Cryptography and Network Security: Principles and Practice (7th Ed.)”, Pearson, 2017.

[8] Lee, W., Stolfo, S. J., “Data Mining Approaches for Intrusion Detection”, Proceedings of the 7th USENIX Security Symposium, San Antonio, TX, 1998.

[9] Breiman, L., Friedman, J., Olshen, R., and Stone, C., “Classification and Regression Trees”, Wadsworth International Group, 1984.

[10] Rumelhart, D. E., Hinton, G. E., Williams, R. J., “Learning representations by back-propagating errors”, Nature, 323(6088), 533-536, 1986.

[11] Chen, T., Guestrin, C., “XGBoost: A Scalable Tree Boosting System”, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785-794, 2016.

[12] Ashby, W. R., “An Introduction to Cybernetics”, Chapman & Hall, 1956.

[13] Arrieta, A. B., et al., “Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI”, Information Fusion, 58, 82-115, 2020.

[14] Gunning, D., “Explainable Artificial Intelligence (XAI)”, Defense Advanced Research Projects Agency (DARPA), Program Update, 2017.

[15] Ribeiro, M. T., Singh, S., Guestrin, C., “Why Should I Trust You?: Explaining the Predictions of Any Classifier”, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 1135-1144, 2016.

[16] Lundberg, S. M., Lee, S.-I., “A Unified Approach to Interpreting Model Predictions”, Advances in Neural Information Processing Systems 30 (NeurIPS 2017), 4765-4774, 2017.

[17] Adadi, A., Berrada, M., “Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)”, IEEE Access, 6, 52138-52160, 2018.

[18] 정일옥, 최우빈, 김수철, “설명 가능한 인공지능(XAI)을 활용한 침입 탐지 신뢰성 강화 방안,” 융합보안 논문지, 22(3), 101-109, 2022.

[19] Arreche, O., Guntur, T., Abdallah, M., “XAI-IDS: Toward Proposing an Explainable Artificial Intelligence Framework for Network Intrusion Detection”, Applied Sciences, 14(10), 4170, 2024.

[20] Keshk, M., Koroniotis, N., Pham, N., Moustafa, N., Turnbull, B., Zomaya, A. Y., “An explainable deep learning-enabled intrusion detection framework in IoT networks”, Information Sciences, 639, 119000, 2023.